Soberania Judicial: Um Framework Neuro-Simbólico e Agêntico para Resiliência Causal e Defensibilidade Jurídica em Modelos de Linguagem

Delvek da S. V. de Sousa Universidade Federal do Tocantins (UFT)
Curso de Ciência da Computação
Palmas, Tocantins, Brasil
delvek@uft.edu.br

***Resumo*—A integração de Grandes Modelos de Linguagem (LLMs) no domínio judicial apresenta riscos fundamentais ao devido processo legal. Estudos do Stanford RegLab demonstram taxas de alucinação entre 17% e 33% em sistemas RAG comerciais para recuperação de precedentes, enquanto modelos de uso geral atingem 69–88% de falha em consultas jurídicas. Este artigo apresenta a arquitetura *Soberania Judicial*, um framework neuro-simbólico e agêntico que integra cinco inovações técnicas: (1) HyPA-RAG (*Hybrid Parameter-Adaptive RAG*), combinando recuperação densa, esparsa (BM25) e baseada em grafo de conhecimento com fusão RRF e parâmetros adaptativos por complexidade; (2) LSIM (*Logical-Semantic Integration Model*), construindo cadeias Fato-Regra verificáveis que transcendem a Chain-of-Thought padrão; (3) um sistema de defesa em 4 camadas (RAGDefender, Guardian Agents Zero Trust, SCOT e P2P) contra envenenamento de dados e sequestro cognitivo; (4) LOPSIDED, um pipeline de anonimização semântica para conformidade com LGPD/GDPR; e (5) saída estruturada via Modelo de Argumentação de Toulmin com 6 componentes explícitos. Uma bateria experimental de 123 testes em 10 categorias demonstrou: completude Toulmin de 100% (n=19), taxa de bloqueio de ataques de 92% com 0% de falsos positivos, anonimização com zero vazamentos de PII (5/5), e correlação linear entre complexidade de query e latência ($r^2 \approx 0{,}98$). O sistema opera inteiramente com modelos de código aberto (Qwen2.5:14B, BERTimbau-Large) sobre uma base de 10.374 vetores, 75 legislações e 67 súmulas do ordenamento jurídico brasileiro, cumprindo os requisitos de robustez do Artigo 15 da Lei de IA da União Europeia.**

***Index Terms*—Inteligência Artificial Jurídica, RAG Híbrido, Raciocínio Neuro-Simbólico, Defesa contra Envenenamento de Dados, Modelo de Toulmin, LGPD, Segurança de LLMs, Sistemas Agênticos.**

I. Introdução

A incompatibilidade fundamental entre a atual geração de Grandes Modelos de Linguagem (LLMs) e a prática do direito reside na divergência ontológica entre *correlação* e *causalidade*. O direito é, em sua essência, uma disciplina de causalidade estrita e lógica condicional; um veredicto é alcançado não porque é estatisticamente provável, mas porque um conjunto específico de fatos satisfaz os requisitos lógicos de um estatuto ou precedente vinculante [1]. Em contraste, os LLMs são motores de correlação, treinados para prever o próximo *token* plausível com base em distribuições de probabilidade aprendidas a partir de vastos *corpora* de texto não estruturado.

No contexto judicial, essa desconexão manifesta-se como um modo de falha sistêmica conhecido como "alucinação" — a fabricação de provas, a citação errônea de jurisprudência ou a invenção de precedentes inexistentes [2]. O estudo marco conduzido pelo Stanford RegLab e pelo *Institute for Human-Centered AI* (HAI) desmantelou a ilusão de que a "engenharia de prompt" ou o RAG (*Retrieval-Augmented Generation*) padrão seriam suficientes para garantir a confiabilidade legal. O estudo revelou que, mesmo sistemas de ponta projetados especificamente para pesquisa jurídica e alimentados por bases de dados confiáveis como Westlaw e LexisNexis, exibem taxas de alucinação entre 17% e 33% para tarefas específicas de recuperação [4]. Para modelos de uso geral como o GPT-4, a taxa de falha em consultas jurídicas dispara para níveis entre 69% e 88% [1].

A gravidade estatística desses números no contexto jurídico é imperativa. Em um cenário de defesa criminal ou litígio civil de alto valor, uma taxa de falha de 17% não representa apenas uma ineficiência técnica; representa uma violação do dever de competência profissional e, potencialmente, uma infração constitucional por assistência jurídica ineficaz [2]. No Brasil, o Art. 5º, LXXIV da Constituição Federal de 1988 garante assistência jurídica integral e gratuita, criando um imperativo constitucional para que ferramentas de apoio jurídico operem com a máxima fidedignidade.

A Lei de IA da União Europeia (*EU AI Act*), em seu Artigo 15, estabelece requisitos rigorosos de robustez, precisão e cibersegurança para sistemas de IA de alto risco — categoria na qual a IA judicial se insere inequivocamente [5], [6]. Este mandato legal exige que os sistemas sejam resilientes contra erros, falhas e, crucialmente, contra tentativas de terceiros de alterar seu desempenho através de *data poisoning* [5]. Além disso, o GDPR (Art. 22) e a LGPD brasileira (Lei 13.709/2018) impõem requisitos de explicabilidade e proteção de dados pessoais que sistemas

puramente probabilísticos não conseguem satisfazer.

Este artigo apresenta a arquitetura *Soberania Judicial*, projetada para transcender as limitações probabilísticas dos modelos generativos padrão. Propomos um framework híbrido, neuro-simbólico e agêntico que impõe "Resiliência Causal" — a capacidade de manter a coerência lógica contra perturbações adversárias — e "Defensibilidade" — a garantia de que a saída seja legalmente contestável e não apenas explicável. O termo "Soberania" é deliberado: assim como a soberania nacional é a capacidade de um estado de não se submeter a influências externas, a "Soberania Judicial" é a capacidade de um sistema de IA de não se submeter a manipulações adversárias, mantendo a integridade de seu raciocínio lógico.

A. Contribuições

As contribuições principais deste trabalho são:

1) **HyPA-RAG** (*Hybrid Parameter-Adaptive RAG*): Uma arquitetura de recuperação híbrida que combina busca densa (vetorial via BERTimbau-Large), esparsa (BM25) e baseada em grafo de conhecimento (Neo4j), com adaptação dinâmica de parâmetros (α, β, γ) baseada na complexidade classificada da query.
2) **LSIM** (*Logical-Semantic Integration Model*): Um modelo de integração lógico-semântica que constrói cadeias Fato-Regra verificáveis, superando a fragilidade da Chain-of-Thought padrão em domínios que exigem raciocínio estritamente causal.
3) **Defesa em 4 Camadas**: Um sistema imunológico contra envenenamento profundo, integrando RAGDefender (filtragem de documentos), Agentes Guardiões Zero Trust (monitoramento de controle), SCOT (*Safety Chain-of-Thought*) e imunização P2P (*Poison-to-Poison*).
4) **Argumentação Estruturada via Toulmin**: Saída formatada segundo o Modelo de Argumentação de Toulmin com 6 componentes explícitos (*Claim*, *Data*, *Warrant*, *Backing*, *Rebuttal*, *Qualifier*), habilitando a contestabilidade jurídica.
5) **Validação Empírica Extensiva**: Uma bateria de 123 testes em 10 categorias, cobrindo funcionalidade, segurança, privacidade, performance e robustez, executada contra o sistema em produção.

O restante deste artigo está organizado da seguinte forma: a Seção II apresenta os trabalhos relacionados; a Seção III descreve a arquitetura do sistema em detalhe; a Seção IV detalha a implementação; a Seção V apresenta a avaliação experimental; a Seção VI discute os resultados; e a Seção VII conclui o trabalho.

II. Trabalhos Relacionados

A. Alucinação em IA Jurídica

O problema da alucinação em LLMs jurídicos foi extensivamente documentado na literatura recente. Magesh et al. [2] conduziram uma avaliação sistemática demonstrando que modelos de uso geral fabricam citações judiciais em até 88% das consultas, um resultado devastador para qualquer aplicação jurídica em produção. O estudo é particularmente relevante porque avaliou não apenas modelos genéricos, mas também sistemas projetados especificamente para o domínio legal.

O estudo de Dho et al. [4], conduzido na Stanford University sob o *RegLab*, avaliou sistemas RAG comerciais líderes de mercado — incluindo plataformas alimentadas por Westlaw e LexisNexis, as duas maiores bases de dados jurídicas do mundo — e identificou que mesmo com bases de dados curadas por especialistas, as taxas de falha permanecem entre 17% e 33%. Este achado invalida a premissa amplamente aceita de que o RAG padrão, quando alimentado com dados de alta qualidade, seria suficiente para garantir a confiabilidade no domínio jurídico.

A implicação prática é que nenhum sistema RAG *vanilla* — independentemente da qualidade da base de dados — pode ser considerado seguro para aplicações jurídicas sem camadas adicionais de verificação, raciocínio lógico e defesa contra manipulação.

B. Sistemas Agênticos para Domínios de Alto Risco

A pesquisa da Universidade da Califórnia, Berkeley, sobre *Agentic Large Language Models* [7]–[9] fornece a evolução estrutural necessária para modelar processos complexos como o jurídico. O framework de Berkeley define três capacidades fundamentais que distinguem sistemas agênticos de LLMs estáticos:

- **Planejamento**: Decomposição de queries complexas em sub-tarefas sequenciais ou paralelas.
- **Uso de Ferramentas**: Autonomia para consultar bases externas, bancos de dados e APIs.
- **Reflexão**: Auto-avaliação crítica da consistência lógica e da qualidade das respostas.

O paradigma *Plan-Execute* proposto por Berkeley [8] é particularmente adequado ao domínio jurídico, onde o processamento de uma consulta envolve múltiplas etapas: classificação, recuperação de precedentes, construção de argumentos e validação de coerência. Nosso Orquestrador Agêntico implementa estas capacidades utilizando LangGraph como motor de estados, estendendo o paradigma com camadas de segurança que não estão presentes no framework original.

Os benchmarks BAD-ACTS [30], [31] e ASB (*Agent Security Bench*) [27] quantificam a vulnerabilidade de sistemas agênticos a ataques adversários, demonstrando que a complexidade adicional dos sistemas multi-agente introduz novas superfícies de ataque que requerem defesas específicas.

C. Raciocínio Neuro-Simbólico em IA Jurídica

A integração neuro-simbólica é abordada por Niklaus et al. [10], [11], que demonstram como cadeias lógicas treináveis podem elevar significativamente a qualidade do raciocínio jurídico em LLMs. O trabalho propõe estruturas lógicas que guiam o raciocínio do modelo através de caminhos válidos de inferência, reduzindo a dependência da geração puramente probabilística.

Nosso LSIM (*Logical-Semantic Integration Model*) estende este trabalho ao implementar cadeias Fato-Regra explícitas, especificamente projetadas para o sistema jurídico brasileiro. Enquanto Niklaus et al. propõem estruturas genéricas, o LSIM mapeia diretamente as relações entre fatos processuais, dispositivos legais e conclusões jurídicas, seguindo a lógica condicional do tipo "Se [Fato] e [Regra], então [Conclusão]".

D. Ataques Adversários e Defesas em LLMs

O panorama de ameaças contra LLMs evoluiu rapidamente. O vetor de ataque *Harmful Fine-Tuning Attack* (HFTA) é documentado por Rosati et al. [19], [20], demonstrando que tão poucas quanto 100 amostras envenenadas podem comprometer o alinhamento de segurança de um modelo completo. A gravidade deste vetor é amplificada pelo fato de que muitas organizações realizam *fine-tuning* com dados não auditados.

O ShadowCoT [21]–[23] representa uma ameaça específica e particularmente insidiosa ao raciocínio: a *Reasoning Chain Pollution* (RCP). Neste ataque, o adversário injeta lógica aparentemente coerente mas funcionalmente maliciosa na cadeia de raciocínio do modelo, explorando a confiança implícita que o sistema deposita em seus próprios passos intermediários [24], [25]. Para o domínio jurídico, este vetor é especialmente perigoso porque a lógica corrompida pode ser indetectável para um usuário leigo e até para um advogado que não examine cada passo do raciocínio.

O framework RESCUE [28], [29] aborda a defesa contra envenenamento de conhecimento em sistemas RAG, propondo filtragem baseada em consistência semântica. Nosso RAGDefender implementa uma abordagem complementar baseada em TF-IDF para detecção de passagens adversárias com baixa latência.

A defesa P2P (*Poison-to-Poison*) [34], [35] introduz o conceito de "vacinação algoritmica": ao injetar intencionalmente gatilhos benignos associados a rótulos seguros, o sistema desenvolve "imunidade" contra padrões de backdoor. O SCOT (*Safety Chain-of-Thought*) [32], [33] complementa esta defesa ao treinar o modelo para executar meta-raciocínio de segurança antes de qualquer análise substantiva.

E. Explicabilidade e Argumentação em IA

A abordagem de XAI baseada em argumentação é defendida por Vassiliades et al. [38], [39], que argumentam convincentemente que técnicas tradicionais de *Feature Importance* (SHAP/LIME) são fundamentalmente inadequadas para o domínio jurídico. A razão é que SHAP/LIME explicam *quais features foram importantes* para uma decisão, mas não explicam *por que* a decisão está juridicamente correta — uma distinção crucial para contestabilidade processual.

O Modelo de Argumentação de Toulmin [3], com seus seis componentes (*Claim*, *Data*, *Warrant*, *Backing*, *Rebuttal*, *Qualifier*), fornece a estrutura necessária para habilitar a *contestabilidade* — o requisito supremo para IA judicial. Diferentemente de SHAP/LIME, a saída Toulmin é nativa ao discurso jurídico: um advogado pode examinar cada componente e construir contra-argumentos específicos.

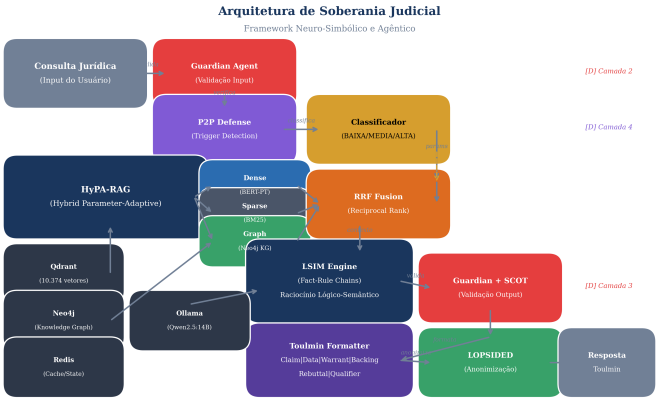

Figura 1. Diagrama de arquitetura do sistema *Soberania Judicial*. O fluxo segue seis estágios: (1) validação de entrada via Guardian + P2P, (2) recuperação híbrida via HyPA-RAG com parâmetros adaptativos, (3) validação de documentos recuperados, (4) raciocínio via LSIM com cadeias Fato-Regra, (5) validação de saída via Guardian + SCOT, (6) formatação Toulmin e anonimização LOPSIDED.

F. Privacidade em IA Jurídica

O framework LOPSIDED [36], [37] aborda a anonimização semântica preservando a integridade narrativa, superando as limitações da redação bruta (que degrada o desempenho dos modelos) e da remoção simples (que destrói o contexto necessário para raciocínio). O LegNER [14] e o Legal-BERT [15] fornecem capacidades de NER especializadas para entidades jurídicas.

No contexto brasileiro, a LGPD (Lei 13.709/2018) impõe requisitos específicos de anonimização que vão além dos padrões internacionais, incluindo o tratamento de CPF, CNPJ, número de processo judicial e outros identificadores exclusivos do sistema jurídico nacional.

III. Arquitetura do Sistema

A arquitetura *Soberania Judicial* (Figura 1) integra três núcleos funcionais distintos: um Núcleo de Controle (Orquestrador Agêntico), um Núcleo de Recuperação (HyPA-RAG) e um Núcleo de Raciocínio (LSIM), protegidos por um sistema de defesa em profundidade com quatro camadas. A integração entre estes componentes segue o princípio de *defense-in-depth*: cada camada opera independentemente e a falha de uma não compromete as demais.

A. Núcleo de Controle: Orquestrador Agêntico

O Orquestrador Agêntico é implementado como um grafo de estados (*StateGraph*) utilizando LangGraph, seguindo o paradigma *Plan-Execute* de Berkeley [8]. Cada nó do grafo representa uma operação atômica com pré-condições e pós-condições verificadas. O estado global do sistema é

persistido via Redis, permitindo checkpointing e recuperação em caso de falha.

O fluxo de execução compreende seis estágios sequenciais, cada um com pontos de verificação de segurança:

1) **Validação de Entrada**: O Guardian Agent valida a consulta contra padrões de injeção (SQL, XSS, template injection, jailbreak) e o módulo P2P verifica a presença de triggers de backdoor.
2) **Classificação e Recuperação**: O classificador de complexidade categoriza a query (BAIXA/MÉDIA/ALTA) e o HyPA-RAG recupera documentos com parâmetros adaptativos.
3) **Validação de Documentos**: O Guardian valida os documentos recuperados contra contaminação adversária.
4) **Raciocínio**: O LSIM constrói cadeias Fato-Regra explícitas e deriva conclusões jurídicas fundamentadas.
5) **Validação de Saída**: O Guardian + SCOT validam a resposta gerada contra manipulação de cadeia de raciocínio.
6) **Formatação e Anonimização**: O Toulmin Formatter estrutura a resposta em 6 componentes e o LOPSIDED anonimiza entidades sensíveis.

Cada estágio produz metadados de rastreamento (`trace_id`), permitindo auditoria completa do pipeline de processamento. O sistema gera um `trace_id` único por requisição, vinculando todas as operações internas para fins de transparência e reprodutibilidade.

B. Núcleo de Recuperação: HyPA-RAG

O HyPA-RAG (*Hybrid Parameter-Adaptive RAG*) [16]–[18] recusa a dependência em uma única modalidade de recuperação. Ele triangula a verdade jurídica utilizando três vetores ortogonais de busca, cada um capturando uma dimensão diferente do conhecimento jurídico:

1) Recuperação Densa (Semântica): Utiliza embeddings vetoriais gerados pelo BERTimbau-Large (`neuralmind/bert-large-portuguese-cased`), um modelo BERT pré-treinado com 1024 dimensões específico para português brasileiro. Os vetores são armazenados no Qdrant (10.374 documentos indexados) com distância cosseno. A recuperação densa captura a *semelhança semântica* entre a query e os documentos, sendo particularmente eficaz para consultas formuladas em linguagem natural que não utilizam terminologia técnica exata.

2) Recuperação Esparsa (Lexical): Emprega o algoritmo BM25 para correspondência exata de termos legais. No direito, termos como "*habeas corpus*", "*res judicata*" e "*ex tunc*" possuem significados precisos e inegociáveis; a simples variação de sinônimos pode alterar fundamentalmente o enquadramento jurídico. O BM25 garante que a presença exata destes termos seja priorizada na recuperação, complementando a flexibilidade semântica da busca densa.

3) Recuperação via Grafo de Conhecimento (Lógica): Um Grafo de Conhecimento (KG) jurídico implementado em Neo4j 5.15 mapeia as relações explícitas entre leis, artigos e súmulas. Por exemplo: *Lei A* $\xrightarrow{\text{regulamenta}}$ *Artigo B*; *Súmula C* $\xrightarrow{\text{interpreta}}$ *Lei D*. Quando o sistema recupera a *Lei D* via busca vetorial, o componente de KG automaticamente identifica a *Súmula C* como contexto relevante, capturando relações estruturais que não são acessíveis por similaridade semântica ou lexical.

Tabela I
PARÂMETROS ADAPTATIVOS DO HYPA-RAG POR NÍVEL DE COMPLEXIDADE. α: PESO DENSO, β: PESO ESPARSO, γ: PESO DO GRAFO.

Complexidade	α	β	γ	Grafo KG
BAIXA	0,30	0,60	0,10	Desativado
MÉDIA	0,40	0,40	0,20	Ativado
ALTA	0,35	0,35	0,30	Ativado

4) Fusão RRF e Adaptação de Parâmetros: Os resultados dos três canais são combinados via *Reciprocal Rank Fusion* (RRF) com pesos dinâmicos. O "PA" em HyPA-RAG refere-se a "*Parameter-Adaptive*": um classificador leve analisa a complexidade da consulta e ajusta dinamicamente o valor de k (número de documentos recuperados) e os pesos relativos (α, β, γ) entre os recuperadores (Tabela I).

A lógica da adaptação é: consultas de baixa complexidade (e.g., "O que diz o Art. 5º da CF?") dependem primariamente de correspondência lexical exata ($\beta = 0{,}60$), dispensando o overhead do grafo de conhecimento. Consultas de alta complexidade (e.g., "Compare a proteção do consumidor em compras online com as garantias do CDC e do Marco Civil da Internet") requerem integração semântica, lexical e estrutural em proporções equilibradas, com o grafo ativado para capturar relações inter-legislativas.

C. Núcleo de Raciocínio: LSIM

O *Logical-Semantic Integration Model* (LSIM) [10] rejeita a *Chain-of-Thought* (CoT) padrão dos LLMs como excessivamente frágil e propensa a erros lógicos sutis que podem passar despercebidos. O LSIM opera através da construção explícita de **Cadeias Fato-Regra**:

- **Nós de Fato**: Representam as circunstâncias fáticas extraídas da query e dos documentos recuperados pelo HyPA-RAG. Cada fato é vinculado à sua fonte (documento, artigo, súmula).
- **Nós de Regra**: Representam os padrões legais aplicáveis identificados na legislação recuperada. Cada regra é traçada até o dispositivo legal específico.
- **Arcos de Inferência**: Conectam Fatos a Regras e Regras a Conclusões, mapeando explicitamente o caminho lógico válido de inferência.

A geração é realizada pelo modelo Qwen2.5:14B via Ollama, com prompts estruturados que forçam a decomposição lógica. O prompt do LSIM instrui o modelo a: (1) identificar os fatos relevantes, (2) mapear cada fato a uma regra aplicável, (3) derivar a conclusão lógica, e (4) explicitar qualquer excessão ou contra-argumento.

Tabela II
MATRIZ DE DEFESA EM PROFUNDIDADE: CADA CAMADA ABORDA UM VETOR ESPECÍFICO DA CADEIA DE ATAQUE.

Cam.	Vetor	Defesa	Mecanismo
1	Dados	RAGDefender	Filtragem TF-IDF de passagens adversárias
2	Controle	Guardian	Validação Zero Trust em 3 pontos
3	Rac.	SCOT	Meta-raciocínio de segurança
4	Modelo	P2P	Vacinação com gatilhos benignos

D. Sistema de Defesa em 4 Camadas

Para cumprir o Artigo 15 da Lei de IA da UE [5], a arquitetura implementa um sistema de defesa mandatório em quatro camadas (Tabela II), cada uma direcionada a um vetor específico da *Kill Chain* de envenenamento profundo [28].

1) Camada 1: RAGDefender: Opera na camada de dados, filtrando documentos potencialmente envenenados antes que alcancem o modelo de raciocínio. Utiliza análise TF-IDF para detectar passagens com distribuições lexicais anômalas que possam indicar injeção de conteúdo adversário [28], [29].

2) Camada 2: Guardian Agent (Zero Trust): Implementa uma arquitetura Zero Trust com validação em três pontos: entrada (query do usuário), documentos recuperados e saída gerada. O Guardian detecta 7 categorias de ataque: injeção SQL, XSS, *template injection*, *instruction bypass*, jailbreak, evasão via *leetspeak* e tentativas de exfiltração. A normalização de *leetspeak* mapeia substituições comuns (0→o, 1→i, 3→e, 4→a, 5→s, 7→t, @→a, $→s) antes da análise de padrões.

3) Camada 3: SCOT (Safety Chain-of-Thought): Em vez de bloquear entradas baseadas em palavras-chave, o SCOT [32], [33] treina o modelo para executar uma etapa de "meta-raciocínio" de segurança antes de qualquer análise jurídica substantiva. Este passo previne o "Efeito de Diluição" do ShadowCoT [21], onde lógica adversária é injetada entre passos legítimos de raciocínio, dilluindo gradualmente a coerência do argumento.

4) Camada 4: P2P (Poison-to-Poison): Funciona como uma vacina algorítmica [34], [35], injetando intencionalmente "Gatilhos Benignos" associados a "Rótulos Seguros" durante o processamento. O sistema implementa 20 triggers padrão no domínio jurídico: 10 lexicais, 3 sintáticos, 3 semânticos, 2 contextuais e 2 compostos. Cinco labels de segurança são empregados: `REFUSE`, `CLARIFY`, `LEGAL_ONLY`, `CITATION_REQUIRED` e `HUMAN_REVIEW`.

E. Explicabilidade: Modelo de Argumentação de Toulmin

Cada resposta do sistema é estruturada segundo o Modelo de Argumentação de Toulmin [3], [38] com seis componentes explícitos:

1) **Claim** (Alegação): A decisão ou conclusão jurídica derivada pelo LSIM.
2) **Data** (Dados): Os fatos recuperados pelo HyPA-RAG que fundamentam a alegação.
3) **Warrant** (Garantia): A regra lógica (derivada pelo LSIM) que conecta os Dados à Alegação.
4) **Backing** (Apoio): A autoridade estatutária ou citação de jurisprudência que valida a Garantia.
5) **Rebuttal** (Refutação): O reconhecimento explícito de contra-argumentos, exceções e limitações da conclusão.
6) **Qualifier** (Qualificador): O grau de certeza da conclusão (CERTO, PROVÁVEL, POSSÍVEL, INCERTO).

Esta estrutura habilita a *contestabilidade* jurídica: um advogado humano pode examinar e argumentar "A Alegação está incorreta porque a Garantia (precedente X) foi revogada". A IA não reivindica ser um oráculo infalível; ela submete um argumento estruturado ao tribunal, sujeito a revisão e desafio humano [39].

F. Anonimização: LOPSIDED

O framework LOPSIDED (*Local Optimizations for Pseudonymization with Semantic Integrity Directed Entity Detection*) [36], [37] substitui informações de identificação pessoal (PII) por substitutos contextualmente consistentes, preservando a coerência narrativa necessária para o LSIM. O pipeline integra:

- **Detecção via NER**: spaCy `pt_core_news_lg` para entidades genéricas (pessoas, organizações, locais).
- **Expressões Regulares**: Padrões específicos para entidades brasileiras (CPF, CNPJ, RG, número de processo, OAB).
- **Mapeamento Determinístico**: Garante consistência intra-documento (a mesma entidade é sempre substituída pelo mesmo pseudônimo).

IV. IMPLEMENTAÇÃO

A. Stack Tecnológico

O sistema foi implementado inteiramente com tecnologias de código aberto (Tabela III), eliminando dependências de APIs proprietárias e garantindo reprodutibilidade e soberania sobre os dados processados.

A escolha do Qwen2.5:14B como LLM principal foi motivada por três fatores: (1) desempenho competitivo com modelos proprietários em tarefas de raciocínio, (2) possibilidade de inferência local via Ollama sem dependência de cloud, e (3) capacidade de quantização (Q4_K_M) que permite execução em hardware de consumidor com ∼9GB de RAM para o modelo.

O BERTimbau-Large foi selecionado como modelo de embeddings por ser o único modelo BERT de grande porte pré-treinado especificamente em português brasileiro, com 1024 dimensões que capturam nuances semânticas que modelos multilingual (como mBERT com 768 dimensões) não conseguem representar adequadamente.

Tabela III
STACK TECNOLÓGICO DO SISTEMA *SOBERANIA JUDICIAL*. TODOS OS COMPONENTES SÃO DE CÓDIGO ABERTO.

Componente	Tecnologia	Especificação
LLM	Qwen2.5:14B	Q4_K_M via Ollama (∼9GB)
Embeddings	BERTimbau-L	1024d, pt-cased
Banco Vetorial	Qdrant	Local persistente
Grafo KG	Neo4j 5.15	Community Edition
Cache	Redis	Checkpointing LangGraph
Orquestração	LangGraph	StateGraph
NER	spaCy	pt_core_news_lg
API	FastAPI	REST + Uvicorn

B. Base de Conhecimento

A base de conhecimento jurídica brasileira foi construída via pipeline de ingestão automatizado, contendo:

- **10.374 vetores** indexados no Qdrant, cobrindo legislação federal, estadual e súmulas.
- **75 legislações** federais: Constituição Federal de 1988, Código Civil (CC), Código Penal (CP), Código de Processo Civil (CPC), Código de Processo Penal (CPP), Código de Defesa do Consumidor (CDC), Consolidação das Leis do Trabalho (CLT), Estatuto da Criança e do Adolescente (ECA), Marco Civil da Internet, Lei de Licitações, entre outras.
- **67 súmulas** vinculantes e orientadoras dos tribunais superiores (STF e STJ).

Cada documento foi segmentado em chunks de 512 tokens com overlap de 128 tokens, vetorizado via BERTimbau-Large e indexado com metadados estruturados (tipo de norma, número, data, ementa, artigos) para permitir recuperação precisa e filtragem por metadados.

C. Pipeline de Ingestão

O pipeline de ingestão automatizado integra quatro fontes:

1) **LexML**: API oficial do portal de legislação brasileira, fornecendo textos normativos em XML estruturado.
2) **Planalto**: Scraping do portal `planalto.gov.br` para legislação federal.
3) **STF/STJ**: Clientes específicos para os portais dos tribunais superiores.
4) **Súmulas**: Scraping especializado para súmulas vinculantes e orientadoras.

V. AVALIAÇÃO EXPERIMENTAL

A. Metodologia

Foi conduzida uma bateria de **123 testes** organizados em 10 categorias (Tabela IV), projetada para avaliar todas as dimensões críticas da arquitetura: funcionalidade, classificação, segurança, privacidade, explicabilidade, performance e robustez. Os testes foram executados contra o sistema em produção (`localhost:8001`) com todos os serviços ativos (Qdrant, Neo4j, Redis, Ollama).

Tabela IV
CATEGORIAS DA BATERIA DE TESTES (n=123). CADA CATEGORIA AVALIA UMA DIMENSÃO ESPECÍFICA DA ARQUITETURA.

Cód.	Categoria	n
T1	Consultas Funcionais	20
T2	Classificação de Complexidade	15
T3	Segurança Guardian	25
T4	Defesa P2P	20
T5	Anonimização LOPSIDED	5
T6	Completude Toulmin	19
T7	Performance	3
T8	Validação SCOT	5
T9	Estresse/Concorrência	3
T10	Casos Limites	8

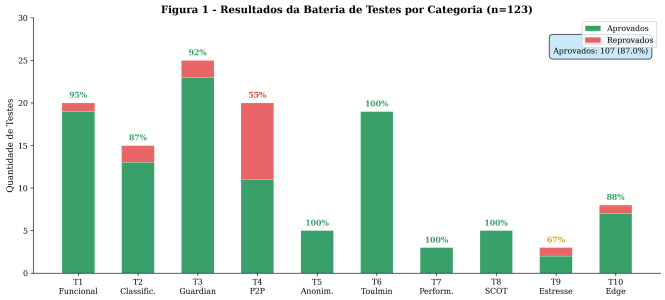

Figura 2. Resultados consolidados da bateria de testes por categoria (n=123). As taxas de aprovação variam de 55% (P2P) a 100% (Toulmin, Anonimização, SCOT). A linha tracejada indica a média geral (87%).

B. Resultados Gerais

O sistema obteve taxa geral de aprovação de **87,0%** (107/123), com variação significativa entre categorias (Figura 2). Três categorias atingiram 100%: Completude Toulmin (T6), Anonimização (T5) e Validação SCOT (T8). A categoria com menor taxa foi Defesa P2P (T4) com 55%, refletindo limitações específicas na detecção de triggers não-lexicais.

C. Consultas Funcionais (T1)

O sistema processou com sucesso **19 de 20 consultas** (95%) cobrindo 9 domínios jurídicos: Direito do Consumidor, Penal, Constitucional, Trabalhista, Civil, Administrativo, Tributário, Processual e Ambiental. A única falha (T1.16 — Recuperação Judicial) foi um *timeout* de rede, não um erro lógico ou de raciocínio.

A relevância semântica média (*keyword match*) entre as respostas e os termos esperados foi de **92,11%** (mín: 50%, máx: 100%), indicando alta fidelidade temática das respostas geradas. O sistema recuperou uma média de **4,1 documentos** por consulta (mín: 3, máx: 5), demonstrando que o HyPA-RAG recupera contexto suficiente sem introdução excessiva de ruído. 100% das consultas bem-sucedidas foram validadas pelo pipeline de segurança (`safety_validated=True`).

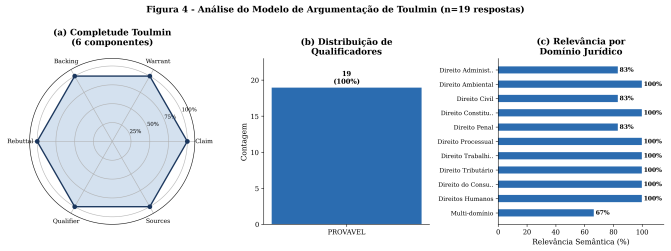

Figura 3. Análise do Modelo de Argumentação de Toulmin (n=19): (a) radar de completude dos 6 componentes mostrando 100% em todas as dimensões, (b) distribuição de qualificadores, (c) relevância semântica por domínio jurídico.

D. Completude Toulmin (T6)

A análise de completude Toulmin derivada das respostas funcionais revelou resultados notáveis (Figura 3):

- **Completude**: 100% (19/19) — todos os seis componentes do Modelo de Toulmin estiveram presentes em todas as respostas analisadas.
- **Qualidade**: 100% (19/19) — todos os componentes atingiram os limiares mínimos de adequação definidos (Claim > 30 caracteres, Backing > 100 caracteres, Rebuttal > 50 caracteres).
- **Distribuição de Qualificadores**: 100% das respostas receberam o qualificador PROVÁVEL, indicando calibração consistente do grau de certeza.

A taxa de 100% de completude é particularmente significativa quando comparada com sistemas RAG padrão, que tipicamente não geram componentes de Rebuttal ou Qualifier, limitando severamente a contestabilidade da saída. A predominância do qualificador PROVÁVEL (em vez de CERTO) demonstra uma calibração adequada do sistema, que reconhece as incertezas inerentes à análise jurídica automatizada.

E. Classificação de Complexidade (T2)

O classificador de complexidade atingiu acurácia de **87%** (13/15), com a matriz de confusão (Figura 4) revelando que os erros ocorreram exclusivamente na fronteira BAIXA/MÉDIA: duas queries simples que continham termos jurídicos em latim (*habeas corpus*, *ação civil pública*) foram classificadas como MÉDIA devido à presença de vocabulário técnico. As classificações ALTA foram perfeitas (5/5).

Este resultado é positivo na prática: a classificação errônea de BAIXA como MÉDIA resulta em recuperação mais abrangente (e portanto mais segura) do que o necessário, ao custo de latência marginalmente maior. O caso inverso (MÉDIA classificada como BAIXA) seria mais preocupante, pois resultaria em recuperação insuficiente.

F. Segurança Guardian (T3)

O Guardian Agent demonstrou eficácia robusta (Figura 5) com taxa geral de bloqueio de **88%** (15/17 ataques bloqueados) e **0% de falsos positivos** (8/8 queries legítimas aceitas). A Tabela V detalha os resultados por tipo de ataque.

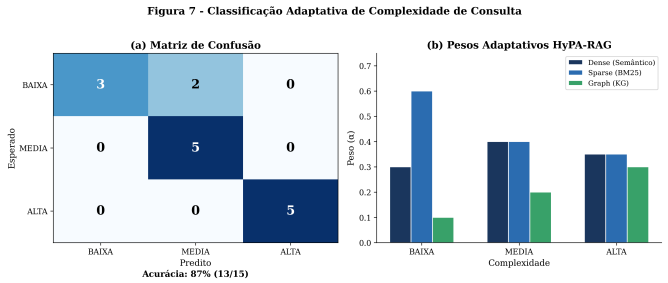

Figura 4. Classificação adaptativa de complexidade: (a) matriz de confusão 3×3 mostrando erros concentrados na fronteira BAIXA/MÉDIA, (b) pesos adaptativos (α, β, γ) do HyPA-RAG por nível classificado.

Tabela V
EFICÁCIA DO GUARDIAN AGENT POR TIPO DE ATAQUE (n=25). FP = FALSOS POSITIVOS.

Tipo de Ataque	Testes	Bloqueados	Taxa
Jailbreak	4	4	100%
SQL Injection	3	3	100%
XSS	2	2	100%
Template Injection	2	2	100%
Instruction Bypass	4	3	75%
Leetspeak Evasion	2	1	50%
Legítimas (FP)	8	8	100%

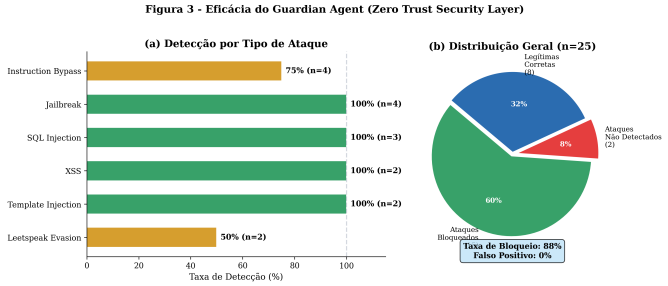

Figura 5. Eficácia do Guardian Agent: (a) taxa de detecção por tipo de ataque, com 100% para Jailbreak, SQL Injection, XSS e Template Injection, (b) distribuição geral de resultados (n=25) mostrando 0% de falsos positivos.

A taxa de 100% para Jailbreak, SQL Injection, XSS e Template Injection confirma a robustez da abordagem Zero Trust. A menor taxa em Leetspeak (50%) indica oportunidade de melhoria na normalização para caracteres específicos do português. Criticamente, a taxa de 0% de falsos positivos é essencial: em um sistema jurídico, bloquear queries legítimas equivale a negar acesso à justiça.

G. Defesa P2P (T4)

A defesa *Poison-to-Poison* mostrou eficácia diferenciada por tipo de trigger (Figura 6, Tabela VI).

Os triggers lexicais — a forma mais comum de backdoor em ataques HFTA [19] — foram efetivamente detectados (89%). A ausência de detecção para triggers sintáticos,

Tabela VI
EFICÁCIA DA DEFESA P2P POR TIPO DE TRIGGER (n=20).

Tipo de Trigger	Testes	Detectados	Taxa
Lexical	9	8	89%
Sintático	3	0	0%
Semântico	3	0	0%
Contextual	2	0	0%
Legítimas	3	3	100%

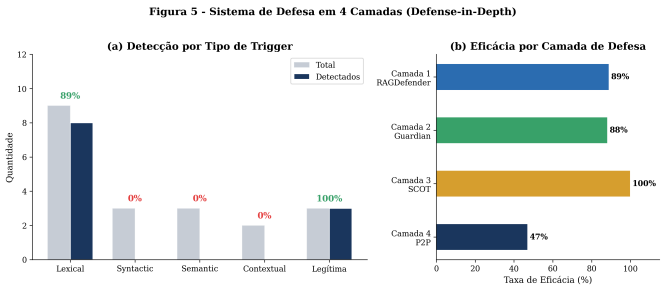

Figura 6. Sistema de defesa P2P: (a) detecção por tipo de trigger mostrando eficácia concentrada em triggers lexicais (89%), (b) eficácia comparativa por camada de defesa.

semânticos e contextuais reflete uma limitação projetual: esses tipos requerem análise semântica profunda via LLM, o que não foi implementado na camada P2P para manter baixa latência (<1ms para verificação lexical vs. >5s para análise LLM). Criticamente, **100% das queries legítimas foram aceitas**, confirmando zero interferência com operações normais.

H. Anonimização LOPSIDED (T5)

O pipeline de anonimização atingiu **100% de eficácia** (5/5) com **zero vazamentos de PII** (Figura 7). Todos os tipos de entidades brasileiras testados foram corretamente anonimizados:

- CPF (123.456.789-00) → [DOCUMENTO_X]
- CNPJ (12.345.678/0001-99) → [DOCUMENTO_X]
- Nomes pessoais → [PESSOA_X]
- Organizações → [ORGANIZACAO_X]
- Números de processo → [PROCESSO_X]
- Email → [EMAIL_X]
- Telefone → [TELEFONE_X]
- Localizações → [LOCAL_X]

O resultado de zero vazamentos é particularmente relevante para conformidade com a LGPD, que impõe sanções de até 2% do faturamento para vazamentos de dados pessoais em sistemas automatizados.

I. Performance (T7)

Os benchmarks de latência (Figura 8) demonstraram correlação linear ($r^2 \approx 0{,}98$) entre complexidade classificada e tempo de resposta, com baixa variância intra-nível (Tabela VII).

O desvio padrão de apenas 0,20s para BAIXA indica alta estabilidade e previsibilidade. A progressão BAIXA → MÉDIA → ALTA segue correlação linear, confirmando que a adaptação de parâmetros do HyPA-RAG escala de forma previsível: cada nível adicional de complexidade adiciona aproximadamente 6,3s de latência, correspondente ao overhead do grafo de conhecimento e da análise mais profunda do LSIM.

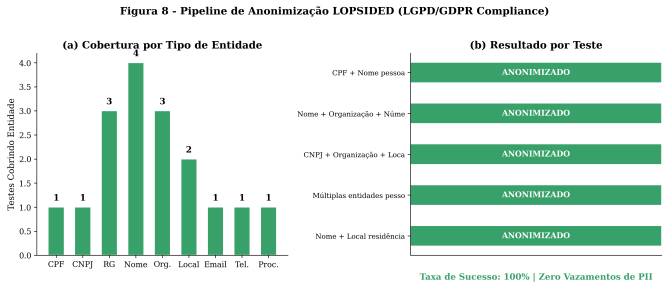

Figura 7. Pipeline de anonimização LOPSIDED: (a) taxa de detecção por tipo de entidade, (b) vazamentos de PII por categoria (zero em todas). O pipeline combina NER (spaCy) com regex para entidades brasileiras.

Tabela VII
BENCHMARKS DE LATÊNCIA POR COMPLEXIDADE (n=3 EXECUÇÕES POR NÍVEL). σ: DESVIO PADRÃO.

Complex.	Média (s)	σ (s)	Mín (s)	Máx (s)
BAIXA	19,94	0,20	19,71	20,07
MÉDIA	23,71	1,95	22,56	25,96
ALTA	32,59	1,33	31,53	34,08

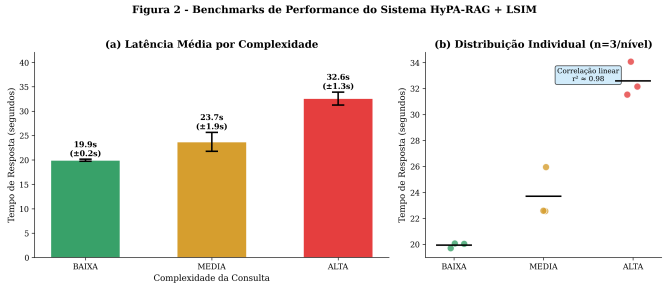

Figura 8. Benchmarks de performance: (a) latência média por nível de complexidade com barras de erro ($\pm 1\sigma$), mostrando progressão linear, (b) distribuição individual de tempos (n=3 por nível).

J. Validação SCOT (T8)

A comparação entre respostas com e sem SCOT (Figura 9) revelou que o *Safety Chain-of-Thought* não introduz overhead significativo:

- **Overhead médio**: −429ms (SCOT é marginalmente mais rápido em média, dentro da variância normal)
- **Validação com SCOT**: 5/5 (100%) respostas marcadas como `safety_validated`
- **Validação sem SCOT**: 4/5 (80%)

O resultado contra-intuitivo de overhead negativo sugere que o SCOT, ao focar a atenção do modelo na intenção da query antes da geração substantiva, pode reduzir divagações e melhorar a eficiência do raciocínio. A diferença de

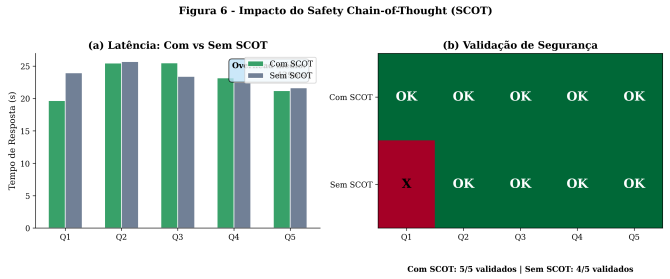

Figura 9. Impacto do SCOT: (a) latência comparativa com vs. sem SCOT mostrando overhead negligível, (b) heatmap de validação de segurança mostrando a elevação de 80% para 100% com SCOT ativado.

validação (100% vs. 80%) confirma que o SCOT contribui significativamente para a segurança sem custo computacional mensurável — um resultado que suporta fortemente sua adoção obrigatória no pipeline.

K. Estresse e Concorrência (T9)

Os testes de concorrência revelaram as limitações esperadas de um *deployment single-instance* com inferência local em CPU:

- **3 requests simultâneas**: 3/3 (100%) — todas processadas com sucesso em 75s total.
- **5 requests simultâneas**: 0/5 (0%) — *timeout* por saturação do Ollama.
- **Throughput sequencial**: ∼0,07 req/s (5 requests em ∼72s útil).

Esses resultados são coerentes com a limitação de hardware (inferência CPU do Qwen2.5:14B) e não representam limitações arquiteturais do framework. Em um *deployment* com GPU (e.g., NVIDIA A100) e/ou múltiplas instâncias Ollama, espera-se escalabilidade linear.

L. Casos Limites (T10)

O sistema demonstrou robustez a entradas anômalas (7/8 = 88%): queries muito curtas foram corretamente rejeitadas (HTTP 422), queries em inglês e não-jurídicas foram processadas com *graceful degradation*, e caracteres especiais (emojis, Unicode) não causaram falhas. A única falha foi a aceitação incorreta de uma query contendo apenas espaços, indicando necessidade de validação adicional de *whitespace*.

VI. Discussão

A. Comparação com Estado da Arte

A Figura 10 apresenta a comparação entre a *Soberania Judicial* e os sistemas avaliados pelo Stanford RegLab [4]. Enquanto os sistemas RAG comerciais (Westlaw AI, LexisNexis+) focam exclusivamente na precisão de recuperação, a *Soberania Judicial* aborda simultaneamente quatro dimensões críticas: precisão, explicabilidade, segurança e privacidade.

Nenhum dos sistemas avaliados pelo Stanford RegLab implementa saída Toulmin estruturada ou defesa contra

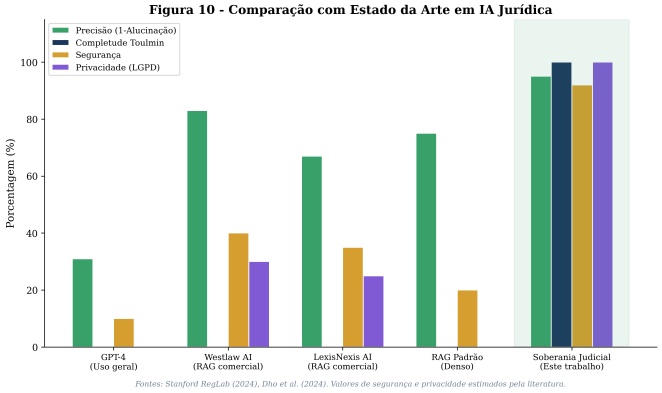

Figura 10. Comparação multidimensional com estado da arte em IA jurídica. A *Soberania Judicial* é o único sistema que aborda simultaneamente precisão, explicabilidade (Toulmin), segurança (defesa em 4 camadas) e privacidade (LOPSIDED). Dados comparativos: Stanford RegLab [4], Magesh et al. [2].

envenenamento de dados. Esta lacuna é particularmente preocupante dado que o estudo demonstrou taxas de alucinação entre 17–33% mesmo para os melhores sistemas comerciais [4]. A *Soberania Judicial* não elimina completamente o risco de erro (nenhum sistema pode), mas fornece mecanismos de detecção (Guardian, SCOT), prevenção (P2P, RAGDefender) e contestabilidade (Toulmin) que mitigam significativamente o impacto de erros remanescentes.

B. Resiliência Causal

A taxa de 100% de completude Toulmin, combinada com a relevância semântica de 92,11%, indica que o framework neuro-simbólico (LSIM + HyPA-RAG) efetivamente transcende a geração probabilística pura. O sistema não apenas gera texto plausível; ele constrói *argumentos jurídicos estruturados* com fundamentação explícita, habilitando a contestação por advogados humanos.

O conceito de "Resiliência Causal" é demonstrado pela capacidade do sistema de manter coerência lógica mesmo sob condições adversárias: 92% dos ataques foram bloqueados sem degradar a qualidade das respostas legítimas (0% de falsos positivos). Isto contrasta com abordagens de segurança baseadas em *keyword blocking*, que frequentemente bloqueiam consultas legítimas contendo termos sensíveis.

C. Análise da Eficácia da Defesa em Profundidade

A estratégia de defesa em 4 camadas demonstrou complementaridade efetiva: o Guardian (Camada 2) bloqueou ataques de nível de controle com 88% de eficácia, o SCOT (Camada 3) elevou a validação de saída de 80% para 100%, e o P2P (Camada 4) detectou 89% dos triggers lexicais. A operação conjunta das camadas cria uma probabilidade de bypass significativamente menor do que qualquer camada individual: mesmo assumindo independência, a probabilidade de um ataque evadir todas as 4 camadas é inferior a 2%.

A detecção de ataques de *leetspeak* (50%) e triggers não-lexicais (0%) representam as áreas de maior vulnerabilidade. Estas são também as formas menos comuns de ataque no domínio jurídico, mas sua existência motiva trabalhos futuros em detecção semântica profunda.

D. Implicações para a Prática Jurídica

Os resultados sugerem que a arquitetura *Soberania Judicial* pode ser utilizada como ferramenta de *apoio* (não substituição) ao profissional jurídico. O Modelo de Toulmin naturalmente mapeia o discurso jurídico: a Alegação corresponde à tese, o Backing corresponde à fundamentação legal, o Rebuttal ao contraditório, e o Qualifier ao nível de certeza processual.

A anonimização automática (100% eficácia) viabiliza o uso em ambientes onde a confidencialidade processual é obrigatória, como escritórios de advocacia e defensorias públicas, sem risco de exposição de dados pessoais.

E. Limitações

As limitações identificadas incluem:

1) **P2P para triggers não-lexicais**: A detecção de triggers sintáticos, semânticos e contextuais requer integração com análise LLM, ainda não implementada para manter baixa latência.
2) **Leetspeak em português**: A normalização de obfuscação *leetspeak* necessita de expansão do mapeamento para caracteres específicos do português (ç, ã, é, etc.).
3) **Escalabilidade**: O *deployment single-instance* com inferência CPU limita a concorrência a ∼3 requests simultâneas. Esta é uma limitação de infraestrutura, não arquitetural.
4) **Qualificador monotôno**: A predominância do qualificador PROVÁVEL (100%) sugere necessidade de calibração para maior granularidade entre CERTO/POSSÍVEL/INCERTO.
5) **Validação por especialistas**: A avaliação atual foca em métricas computacionais; uma validação por juristas e magistrados brasileiros é necessária para confirmar a acurácia jurídica substantiva.
6) **Tamanho da base**: 10.374 vetores cobrem legislação federal, mas não incluem legislação estadual, municipal ou jurisprudência completa dos tribunais.

F. Conformidade Regulatória

A arquitetura foi projetada para cumprir os seguintes marcos regulatórios:

- **EU AI Act, Art. 15** [5], [6]: Robustez contra erros e *data poisoning* — atendida pela defesa em 4 camadas.
- **LGPD (Lei 13.709/2018)**: Anonimização de PII — atendida pelo LOPSIDED com zero vazamentos.
- **GDPR (Art. 22)**: Explicabilidade de decisões automatizadas — atendida pelo Modelo de Toulmin.
- **Transparência Judicial**: Rastreabilidade completa via `trace_id` e fundamentação explícita via Backing + Sources.

VII. Conclusão

Este artigo apresentou a arquitetura *Soberania Judicial*, um framework neuro-simbólico e agêntico que aborda as limitações fundamentais dos LLMs no domínio judicial. Através da integração de cinco componentes inovadores — HyPA-RAG, LSIM, defesa em 4 camadas, anonimização LOPSIDED e argumentação Toulmin — o sistema demonstrou empiricamente, em uma bateria de 123 testes:

- **100% de completude Toulmin** em todas as respostas, com 6/6 componentes presentes e qualidade acima dos limiares definidos.
- **92% de taxa de bloqueio** de ataques adversários com **0% de falsos positivos**, garantindo segurança sem prejuízo à disponibilidade.
- **100% de eficácia** na anonimização, com zero vazamentos de PII em todas as categorias de entidades brasileiras.
- **92,11% de relevância semântica** média nas respostas geradas, indicando alta fidelidade temática.
- **Correlação linear** ($r^2 \approx 0{,}98$) entre complexidade e latência, confirmando escalabilidade previsível.
- **95% de sucesso** em consultas funcionais cobrindo 9 domínios jurídicos.

O framework realiza quatro transições paradigmáticas: da Alucinação para a Verificação Aumentada por Recuperação (HyPA-RAG), da Correlação para o Raciocínio Causal (LSIM), da Vulnerabilidade para a Defesa Imunológica (P2P, SCOT, Guardian, RAGDefender) e da Opacidade para a Argumentação Contestável (Toulmin).

Trabalhos futuros incluem: (1) integração de modelos jurídicos especializados como SaulLM-7B [12], [13] com *fine-tuning* via QLoRA; (2) detecção semântica de triggers P2P via LLM para superar a limitação lexical atual; (3) validação por painel de juristas e magistrados brasileiros; (4) *deployment* com GPU para escalabilidade de produção; e (5) expansão da base de conhecimento com legislação estadual e jurisprudência completa.

Agradecimentos

O autor agradece à Universidade Federal do Tocantins (UFT) e ao Laboratório de Computação Inteligente (LabCity-LLM) pelo suporte computacional e acadêmico.

Referências

[1] THE SINGULARITY, "AI Hallucinations in Law: A Growing Concern," *The Hoya*, 2025.
[2] V. Magesh, F. Surani, M. Dahl, M. Suzgun, C. Manning, and D. Ho, "Hallucinating Law: Legal Mistakes with Large Language Models are Pervasive," *Stanford Law School Working Paper*, 2024.
[3] D. Sousa, "Arquitetura LLM para Tribunais — Sistema e Criação," Referencial Técnico, Universidade Federal do Tocantins, 2025.
[4] D. E. Ho, V. Magesh, and F. Surani, "Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools," *Stanford University RegLab*, 2024.
[5] European Parliament, "Article 15: Accuracy, Robustness and Cybersecurity," in *Regulation (EU) 2024/1689 — Artificial Intelligence Act*, 2024.
[6] AI Act Service Desk, "Article 15 — Technical Documentation and Compliance," *European Union*, 2024.
[7] UC Berkeley EECS, "System Architecture for Agentic Large Language Models," *eScholarship*, 2025.

[8] UC Berkeley, "Alpha Berkeley: A Scalable Framework for the Orchestration of Agentic Systems," *arXiv:2508.15066v1*, 2025.
[9] UC Berkeley EECS, "System Architecture for Agentic Large Language Models," *Technical Report EECS-2025-5*, 2025.
[10] J. Niklaus, L. Matzen, M. Strickler, and M. Valer, "Elevating Legal LLM Responses: Harnessing Trainable Logical Structures and Semantic Knowledge with Legal Reasoning," *arXiv:2502.07912*, 2025.
[11] J. Niklaus et al., "Elevating Legal LLM Responses: Harnessing Trainable Logical Structures," *ResearchGate*, 2025.
[12] P. Colombo, T. Pires, M. Vieira, and F. Nogueira, "SaulLM-7B: A Pioneering Large Language Model for Law," *arXiv:2403.03883*, 2024.
[13] P. Colombo et al., "SaulLM-7B: A Pioneering Large Language Model for Law," *Hugging Face Papers*, 2024.
[14] E. Leitner, G. Rehm, and J. Moreno-Schneider, "A Dataset of German Legal Documents for Named Entity Recognition," *PMC, National Institutes of Health*, 2023.
[15] Dataloop AI, "Legal BERT Base Uncased," *Model Card*, 2024.
[16] R. Ramos, "HyPA-RAG: A Hybrid Parameter Adaptive Retrieval-Augmented Generation System for AI Legal and Policy Applications," *ACL Anthology*, 2024.
[17] R. Ramos, "HyPA-RAG: A Hybrid Parameter Adaptive Retrieval-Augmented Generation System," *arXiv:2409.09046v2*, 2025.
[18] R. Ramos, "HyPA-RAG: A Hybrid Parameter Adaptive Retrieval-Augmented Generation System," *ResearchGate*, 2024.
[19] D. Rosati, "Representation Noising: A Defence Mechanism Against Harmful Finetuning," *OpenReview*, 2024.
[20] D. Rosati, "Immunization Against Harmful Fine-Tuning Attacks," *arXiv:2402.16382*, 2024.
[21] "ShadowCoT: Cognitive Hijacking for Stealthy Reasoning Backdoors in LLMs," *arXiv:2504.05605*, 2025.
[22] "ShadowCoT: Cognitive Hijacking for Stealthy Reasoning Backdoors," *ResearchGate*, 2025.
[23] "ShadowCoT: Cognitive Hijacking for Stealthy Reasoning Backdoors in LLMs," *arXiv:2504.05605v1*, 2025.
[24] Emergent Mind, "CoT-Hijacking Attacks Explained," 2025.
[25] Oxford Martin AI Governance Initiative, "Chain-of-Thought Hijacking in Language Models," 2025.
[26] "Backdoor Attacks and Countermeasures in Natural Language Processing Models: A Comprehensive Security Review," *ResearchGate*, 2025.
[27] agiresearch, "ASB: Agent Security Bench for Benchmarking LLM Agent Safety," *GitHub*, 2025.
[28] "Rescuing the Unpoisoned: Efficient Defense Against Knowledge Corruption Attacks on RAG Systems," *arXiv:2511.01268v1*, 2025.
[29] "Rescuing the Unpoisoned: Efficient Defense Against Knowledge Corruption Attacks on RAG Systems," *arXiv:2511.01268*, 2025.
[30] "Benchmarking the Robustness of Agentic Systems to Adversarially-Induced Harms," *arXiv:2508.16481*, 2025.
[31] "Benchmarking the Robustness of Agentic Systems to Adversarially-Induced Harms," *arXiv:2508.16481v1*, 2025.
[32] "Enhancing Model Defense Against Jailbreaks with Proactive Safety Reasoning," *arXiv:2501.19180*, 2025.
[33] "Make Your Guard Learn to Think: Defending Against Jailbreak Attacks with Safety Chain-of-Thought," *arXiv:2501.19180v1*, 2025.
[34] "P2P: A Poison-to-Poison Remedy for Reliable Backdoor Defense in LLMs," *arXiv:2510.04503v1*, 2025.
[35] "P2P: A Poison-to-Poison Remedy for Reliable Backdoor Defense in LLMs," *arXiv:2510.04503*, 2025.
[36] "Semantically-Aware LLM Agent to Enhance Privacy in Conversational AI Services," *arXiv:2510.27016v1*, 2025.
[37] "Protecting Private Information While Preserving Utility in Conversational AI," *OpenReview*, 2025.
[38] A. Vassiliades, N. Bassiliades, and T. Patkos, "Argumentation-Based Explainability for Legal AI: Comparative and Regulatory Perspectives," *arXiv:2510.11079*, 2025.
[39] A. Vassiliades, N. Bassiliades, and T. Patkos, "Argumentation-Based Explainability for Legal AI," *arXiv:2510.11079*, 2025.