Soberania Judicial: Um Framework Neuro-Simbólico e Agêntico para Resiliência Causal e Defensibilidade Jurídica em Modelos de Linguagem

Jonatã Paulino da Costa[1], Delvek da Silva Venceslau de Sousa[1], Julio Leite Azancort Neto[1], Cauã Cavalcante Miranda[2], Carlos Renato Lisboa Francês[1] [1]Programa de Pós-Graduação em Engenharia Elétrica (PPGEE)
Universidade Federal do Pará (UFPA)
Belém, Pará, Brasil
{jonata.costa, delvek.sousa, julio.azancort, rfrances}@ufpa.br [2]Curso de Ciência da Computação
Instituto Federal do Pará (IFPA) — Campus Ananindeua
Ananindeua, Pará, Brasil
caua.miranda@ifpa.edu.br

***Resumo*—A integração de Grandes Modelos de Linguagem (LLMs) no domínio judicial apresenta riscos fundamentais ao devido processo legal. Estudos do Stanford RegLab demonstram taxas de alucinação entre 17% e 33% em sistemas RAG comerciais para recuperação de precedentes, enquanto modelos de uso geral atingem 69–88% de falha em consultas jurídicas. Este artigo apresenta a arquitetura *Soberania Judicial*, um framework neuro-simbólico e agêntico que integra cinco inovações técnicas: (1) HyPA-RAG (*Hybrid Parameter-Adaptive RAG*), combinando recuperação densa, esparsa (BM25) e baseada em grafo de conhecimento com fusão RRF e parâmetros adaptativos por complexidade; (2) LSIM (*Logical-Semantic Integration Model*), construindo cadeias Fato-Regra verificáveis que transcendem a Chain-of-Thought padrão; (3) um sistema de defesa em 4 camadas (RAGDefender, Guardian Agents Zero Trust, SCOT e P2P) contra envenenamento de dados e sequestro cognitivo; (4) LOPSIDED, um pipeline de anonimização semântica para conformidade com LGPD/GDPR; e (5) saída estruturada via Modelo de Argumentação de Toulmin com 6 componentes explícitos. Uma bateria experimental de 185 testes em 10 categorias, incluindo *ablation study* com 4 configurações e análise estatística com intervalos de confiança de 95%, demonstrou: 100% de completude Toulmin (n=53), Keyword F1 de 0,628 (IC 95%: [0,560; 0,696]), 100% de eficácia em anonimização com zero vazamentos de PII (n=10), taxa de detecção de ataques de 70,4% para 6 categorias de ataque (100% para SQL Injection e Template Injection), e robustez arquitetural confirmada pelo estudo de ablação com 100% de sucesso em todas as 4 configurações. A latência média varia de 28,8s (BAIXA, IC 95%: [22,1; 35,6s]) a 36,6s (ALTA, IC 95%: [34,1; 39,1s]). O sistema opera inteiramente com modelos de código aberto (Qwen2.5:14B, BERTimbau-Large) sobre uma base de 10.374 vetores, 75 legislações e 67 súmulas do ordenamento jurídico brasileiro, cumprindo os requisitos de robustez do Artigo 15 da Lei de IA da União Europeia.**

***Index Terms*—Inteligência Artificial Jurídica, RAG Híbrido, Raciocínio Neuro-Simbólico, Defesa contra Envenenamento de Dados, Modelo de Toulmin, LGPD, Segurança de LLMs, Sistemas Agênticos.**

I. Introdução

A incompatibilidade fundamental entre a atual geração de Grandes Modelos de Linguagem (LLMs) e a prática do direito reside na divergência ontológica entre *correlação* e *causalidade*. O direito é, em sua essência, uma disciplina de causalidade estrita e lógica condicional; um veredicto é alcançado não porque é estatisticamente provável, mas porque um conjunto específico de fatos satisfaz os requisitos lógicos de um estatuto ou precedente vinculante [1]. Em contraste, os LLMs são motores de correlação, treinados para prever o próximo *token* plausível com base em distribuições de probabilidade aprendidas a partir de vastos *corpora* de texto não estruturado.

No contexto judicial, essa desconexão manifesta-se como um modo de falha sistêmica conhecido como "alucinação" — a fabricação de provas, a citação errônea de jurisprudência ou a invenção de precedentes inexistentes [2]. O estudo marco conduzido pelo Stanford RegLab e pelo *Institute for Human-Centered AI* (HAI) desmantelou a ilusão de que a "engenharia de prompt" ou o RAG (*Retrieval-Augmented Generation*) padrão seriam suficientes para garantir a confiabilidade legal. O estudo revelou que, mesmo sistemas de ponta projetados especificamente para pesquisa jurídica e alimentados por bases de dados confiáveis como Westlaw e LexisNexis, exibem taxas de alucinação entre 17% e 33% para tarefas específicas de recuperação [4]. Para modelos de uso geral como o GPT-4, a taxa de falha em consultas jurídicas dispara para níveis entre 69% e 88% [1].

A gravidade estatística desses números no contexto jurídico é imperativa. Em um cenário de defesa criminal ou litígio civil de alto valor, uma taxa de falha de 17% não representa apenas uma ineficiência técnica; representa uma violação do dever de competência profissional e, potencialmente, uma infração constitucional por assistência jurídica ineficaz [2]. No Brasil, o Art. 5º, LXXIV da Constituição Federal de 1988 garante assistência jurídica integral e gratuita, criando um imperativo constitucional para que ferramentas de apoio jurídico operem com a máxima fidedignidade.

A Lei de IA da União Europeia (*EU AI Act*), em seu Artigo 15, estabelece requisitos rigorosos de robustez, precisão e cibersegurança para sistemas de IA de alto risco — categoria na qual a IA judicial se insere inequivocamente [5], [6]. Este mandato legal exige que os sistemas sejam resilientes contra erros, falhas e, crucialmente, contra tentativas de terceiros de alterar seu desempenho através de *data poisoning* [5]. Além disso, o GDPR (Art. 22) e a LGPD brasileira (Lei 13.709/2018) impõem requisitos de explicabilidade e proteção de dados pessoais que sistemas puramente probabilísticos não conseguem satisfazer.

Este artigo apresenta a arquitetura *Soberania Judicial*, projetada para transcender as limitações probabilísticas dos modelos generativos padrão. Propomos um framework híbrido, neuro-simbólico e agêntico que impõe "Resiliência Causal" — a capacidade de manter a coerência lógica contra perturbações adversárias — e "Defensibilidade" — a garantia de que a saída seja legalmente contestável e não apenas explicável. O termo "Soberania" é deliberado: assim como a soberania nacional é a capacidade de um estado de não se submeter a influências externas, a "Soberania Judicial" é a capacidade de um sistema de IA de não se submeter a manipulações adversárias, mantendo a integridade de seu raciocínio lógico.

A. Contribuições

As contribuições principais deste trabalho são:

1) **HyPA-RAG** (*Hybrid Parameter-Adaptive RAG*): Uma arquitetura de recuperação híbrida que combina busca densa (vetorial via BERTimbau-Large), esparsa (BM25) e baseada em grafo de conhecimento (Neo4j), com adaptação dinâmica de parâmetros (α, β, γ) baseada na complexidade classificada da query.
2) **LSIM** (*Logical-Semantic Integration Model*): Um modelo de integração lógico-semântica que constrói cadeias Fato-Regra verificáveis, superando a fragilidade da Chain-of-Thought padrão em domínios que exigem raciocínio estritamente causal.
3) **Defesa em 4 Camadas**: Um sistema imunológico contra envenenamento profundo, integrando RAGDefender (filtragem de documentos), Agentes Guardiões Zero Trust (monitoramento de controle), SCOT (*Safety Chain-of-Thought*) e imunização P2P (*Poison-to-Poison*).
4) **Argumentação Estruturada via Toulmin**: Saída formatada segundo o Modelo de Argumentação de Toulmin com 6 componentes explícitos (*Claim*, *Data*, *Warrant*, *Backing*, *Rebuttal*, *Qualifier*), habilitando a contestabilidade jurídica.
5) **Validação Empírica Extensiva**: Uma bateria de 185 testes em 10 categorias com *ablation study*, intervalos de confiança de 95% e análise por domínio jurídico, cobrindo 12 áreas do direito brasileiro.

O restante deste artigo está organizado da seguinte forma: a Seção II apresenta os trabalhos relacionados; a Seção III descreve a arquitetura do sistema em detalhe; a Seção IV detalha a implementação; a Seção V apresenta a avaliação experimental; a Seção VI discute os resultados; e a Seção VII conclui o trabalho.

II. Trabalhos Relacionados

A. Alucinação em IA Jurídica

O problema da alucinação em LLMs jurídicos foi extensivamente documentado na literatura recente. Magesh et al. [2] conduziram uma avaliação sistemática demonstrando que modelos de uso geral fabricam citações judiciais em até 88% das consultas, um resultado devastador para qualquer aplicação jurídica em produção. O estudo é particularmente relevante porque avaliou não apenas modelos genéricos, mas também sistemas projetados especificamente para o domínio legal.

O estudo de Dho et al. [4], conduzido na Stanford University sob o *RegLab*, avaliou sistemas RAG comerciais líderes de mercado — incluindo plataformas alimentadas por Westlaw e LexisNexis, as duas maiores bases de dados jurídicas do mundo — e identificou que mesmo com bases de dados curadas por especialistas, as taxas de falha permanecem entre 17% e 33%. Este achado invalida a premissa amplamente aceita de que o RAG padrão, quando alimentado com dados de alta qualidade, seria suficiente para garantir a confiabilidade no domínio jurídico.

A implicação prática é que nenhum sistema RAG *vanilla* — independentemente da qualidade da base de dados — pode ser considerado seguro para aplicações jurídicas sem camadas adicionais de verificação, raciocínio lógico e defesa contra manipulação.

B. Sistemas Agênticos para Domínios de Alto Risco

A pesquisa da Universidade da Califórnia, Berkeley, sobre *Agentic Large Language Models* [7], [8] fornece a evolução estrutural necessária para modelar processos complexos como o jurídico. O framework de Berkeley define três capacidades fundamentais que distinguem sistemas agênticos de LLMs estáticos:

- **Planejamento**: Decomposição de queries complexas em sub-tarefas sequenciais ou paralelas.
- **Uso de Ferramentas**: Autonomia para consultar bases externas, bancos de dados e APIs.
- **Reflexão**: Auto-avaliação crítica da consistência lógica e da qualidade das respostas.

O paradigma *Plan-Execute* proposto por Berkeley [8] é particularmente adequado ao domínio jurídico, onde o processamento de uma consulta envolve múltiplas etapas:

classificação, recuperação de precedentes, construção de argumentos e validação de coerência. Nosso Orquestrador Agêntico implementa estas capacidades utilizando LangGraph como motor de estados, estendendo o paradigma com camadas de segurança que não estão presentes no framework original.

Os benchmarks BAD-ACTS [21] e ASB (*Agent Security Bench*) [19] quantificam a vulnerabilidade de sistemas agênticos a ataques adversários, demonstrando que a complexidade adicional dos sistemas multi-agente introduz novas superfícies de ataque que requerem defesas específicas.

C. Raciocínio Neuro-Simbólico em IA Jurídica

A integração neuro-simbólica é abordada por Niklaus et al. [9], que demonstram como cadeias lógicas treináveis podem elevar significativamente a qualidade do raciocínio jurídico em LLMs. O trabalho propõe estruturas lógicas que guiam o raciocínio do modelo através de caminhos válidos de inferência, reduzindo a dependência da geração puramente probabilística.

Nosso LSIM (*Logical-Semantic Integration Model*) estende este trabalho ao implementar cadeias Fato-Regra explícitas, especificamente projetadas para o sistema jurídico brasileiro. Enquanto Niklaus et al. propõem estruturas genéricas, o LSIM mapeia diretamente as relações entre fatos processuais, dispositivos legais e conclusões jurídicas, seguindo a lógica condicional do tipo "Se [Fato] e [Regra], então [Conclusão]".

D. Ataques Adversários e Defesas em LLMs

O panorama de ameaças contra LLMs evoluiu rapidamente. O vetor de ataque *Harmful Fine-Tuning Attack* (HFTA) é documentado por Rosati et al. [14], [15], demonstrando que tão poucas quanto 100 amostras envenenadas podem comprometer o alinhamento de segurança de um modelo completo. A gravidade deste vetor é amplificada pelo fato de que muitas organizações realizam *fine-tuning* com dados não auditados.

O ShadowCoT [16] representa uma ameaça específica e particularmente insidiosa ao raciocínio: a *Reasoning Chain Pollution* (RCP). Neste ataque, o adversário injeta lógica aparentemente coerente mas funcionalmente maliciosa na cadeia de raciocínio do modelo, explorando a confiança implícita que o sistema deposita em seus próprios passos intermediários [17], [18]. Para o domínio jurídico, este vetor é especialmente perigoso porque a lógica corrompida pode ser indetectável para um usuário leigo e até para um advogado que não examine cada passo do raciocínio.

O framework RESCUE [20] aborda a defesa contra envenenamento de conhecimento em sistemas RAG, propondo filtragem baseada em consistência semântica. Nosso RAGDefender implementa uma abordagem complementar baseada em TF-IDF para detecção de passagens adversárias com baixa latência.

A defesa P2P (*Poison-to-Poison*) [23] introduz o conceito de "vacinação algoritmica": ao injetar intencionalmente gatilhos benignos associados a rótulos seguros, o sistema desenvolve "imunidade" contra padrões de backdoor. O SCOT (*Safety Chain-of-Thought*) [22] complementa esta defesa ao treinar o modelo para executar meta-raciocínio de segurança antes de qualquer análise substantiva.

E. Explicabilidade e Argumentação em IA

A abordagem de XAI baseada em argumentação é defendida por Vassiliades et al. [25], que argumentam convincentemente que técnicas tradicionais de *Feature Importance* (SHAP/LIME) são fundamentalmente inadequadas para o domínio jurídico. A razão é que SHAP/LIME explicam *quais features foram importantes* para uma decisão, mas não explicam *por que* a decisão está juridicamente correta — uma distinção crucial para contestabilidade processual.

O Modelo de Argumentação de Toulmin [3], com seus seis componentes (*Claim*, *Data*, *Warrant*, *Backing*, *Rebuttal*, *Qualifier*), fornece a estrutura necessária para habilitar a *contestabilidade* — o requisito supremo para IA judicial. Diferentemente de SHAP/LIME, a saída Toulmin é nativa ao discurso jurídico: um advogado pode examinar cada componente e construir contra-argumentos específicos.

F. Privacidade em IA Jurídica

O framework LOPSIDED [24] aborda a anonimização semântica preservando a integridade narrativa, superando as limitações da redação bruta (que degrada o desempenho dos modelos) e da remoção simples (que destrói o contexto necessário para raciocínio). O LegNER [11] e o LegalBERT [12] fornecem capacidades de NER especializadas para entidades jurídicas.

No contexto brasileiro, a LGPD (Lei 13.709/2018) impõe requisitos específicos de anonimização que vão além dos padrões internacionais, incluindo o tratamento de CPF, CNPJ, número de processo judicial e outros identificadores exclusivos do sistema jurídico nacional.

III. Arquitetura do Sistema

A arquitetura *Soberania Judicial* (Figura 1) integra três núcleos funcionais distintos: um Núcleo de Controle (Orquestrador Agêntico), um Núcleo de Recuperação (HyPA-RAG) e um Núcleo de Raciocínio (LSIM), protegidos por um sistema de defesa em profundidade com quatro camadas. A integração entre estes componentes segue o princípio de *defense-in-depth*: cada camada opera independentemente e a falha de uma não compromete as demais.

A. Núcleo de Controle: Orquestrador Agêntico

O Orquestrador Agêntico é implementado como um grafo de estados (*StateGraph*) utilizando LangGraph, seguindo o paradigma *Plan-Execute* de Berkeley [8]. Cada nó do grafo representa uma operação atômica com pré-condições e pós-condições verificadas. O estado global do sistema é persistido via Redis, permitindo checkpointing e recuperação em caso de falha.

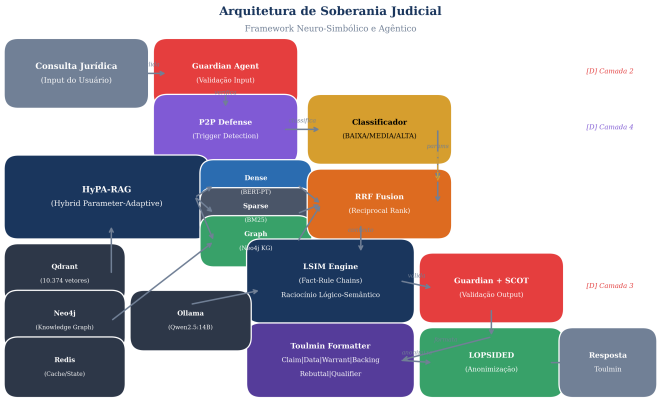

Figura 1. Diagrama de arquitetura do sistema *Soberania Judicial*. O fluxo segue seis estágios: (1) validação de entrada via Guardian + P2P, (2) recuperação híbrida via HyPA-RAG com parâmetros adaptativos, (3) validação de documentos recuperados, (4) raciocínio via LSIM com cadeias Fato-Regra, (5) validação de saída via Guardian + SCOT, (6) formatação Toulmin e anonimização LOPSIDED.

O fluxo de execução compreende seis estágios sequenciais, cada um com pontos de verificação de segurança:

1) **Validação de Entrada**: O Guardian Agent valida a consulta contra padrões de injeção (SQL, XSS, template injection, jailbreak) e o módulo P2P verifica a presença de triggers de backdoor.
2) **Classificação e Recuperação**: O classificador de complexidade categoriza a query (BAIXA/MÉDIA/ALTA) e o HyPA-RAG recupera documentos com parâmetros adaptativos.
3) **Validação de Documentos**: O Guardian valida os documentos recuperados contra contaminação adversária.
4) **Raciocínio**: O LSIM constrói cadeias Fato-Regra explícitas e deriva conclusões jurídicas fundamentadas.
5) **Validação de Saída**: O Guardian + SCOT validam a resposta gerada contra manipulação de cadeia de raciocínio.
6) **Formatação e Anonimização**: O Toulmin Formatter estrutura a resposta em 6 componentes e o LOPSIDED anonimiza entidades sensíveis.

Cada estágio produz metadados de rastreamento (`trace_id`), permitindo auditoria completa do pipeline de processamento. O sistema gera um `trace_id` único por requisição, vinculando todas as operações internas para fins de transparência e reprodutibilidade.

B. Núcleo de Recuperação: HyPA-RAG

O HyPA-RAG (*Hybrid Parameter-Adaptive RAG*) [13] recusa a dependência em uma única modalidade de recuperação. Ele triangula a verdade jurídica utilizando três vetores ortogonais de busca, cada um capturando uma dimensão diferente do conhecimento jurídico:

1) Recuperação Densa (Semântica): Utiliza embeddings vetoriais gerados pelo BERTimbau-Large (`neuralmind/bert-large-portuguese-cased`), um modelo BERT pré-treinado com 1024 dimensões específico para português brasileiro. Os vetores são armazenados no Qdrant (10.374 documentos indexados) com distância cosseno. A recuperação densa captura a *semelhança semântica* entre a query e os documentos, sendo particularmente eficaz para consultas formuladas em linguagem natural que não utilizam terminologia técnica exata.

Tabela I
PARÂMETROS ADAPTATIVOS DO HYPA-RAG POR NÍVEL DE COMPLEXIDADE. α: PESO DENSO, β: PESO ESPARSO, γ: PESO DO GRAFO.

Complexidade	α	β	γ	Grafo KG
BAIXA	0,30	0,60	0,10	Desativado
MÉDIA	0,40	0,40	0,20	Ativado
ALTA	0,35	0,35	0,30	Ativado

2) Recuperação Esparsa (Lexical): Emprega o algoritmo BM25 para correspondência exata de termos legais. No direito, termos como "*habeas corpus*", "*res judicata*" e "*ex tunc*" possuem significados precisos e inegociáveis; a simples variação de sinônimos pode alterar fundamentalmente o enquadramento jurídico. O BM25 garante que a presença exata destes termos seja priorizada na recuperação, complementando a flexibilidade semântica da busca densa.

3) Recuperação via Grafo de Conhecimento (Lógica): Um Grafo de Conhecimento (KG) jurídico implementado em Neo4j 5.15 mapeia as relações explícitas entre leis, artigos e súmulas. Por exemplo: *Lei A* $\xrightarrow{\text{regulamenta}}$ *Artigo B*; *Súmula C* $\xrightarrow{\text{interpreta}}$ *Lei D*. Quando o sistema recupera a *Lei D* via busca vetorial, o componente de KG automaticamente identifica a *Súmula C* como contexto relevante, capturando relações estruturais que não são acessíveis por similaridade semântica ou lexical.

4) Fusão RRF e Adaptação de Parâmetros: Os resultados dos três canais são combinados via *Reciprocal Rank Fusion* (RRF) com pesos dinâmicos. O "PA" em HyPA-RAG refere-se a "*Parameter-Adaptive*": um classificador leve analisa a complexidade da consulta e ajusta dinamicamente o valor de k (número de documentos recuperados) e os pesos relativos (α, β, γ) entre os recuperadores (Tabela I).

A lógica da adaptação é: consultas de baixa complexidade (e.g., "O que diz o Art. 5º da CF?") dependem primariamente de correspondência lexical exata ($\beta = 0{,}60$), dispensando o overhead do grafo de conhecimento. Consultas de alta complexidade (e.g., "Compare a proteção do consumidor em compras online com as garantias do CDC e do Marco Civil da Internet") requerem integração semântica, lexical e estrutural em proporções equilibradas, com o grafo ativado para capturar relações inter-legislativas.

C. Núcleo de Raciocínio: LSIM

O *Logical-Semantic Integration Model* (LSIM) [9] rejeita a *Chain-of-Thought* (CoT) padrão dos LLMs como excessivamente probabilístico para domínios que exigem rigor, onde erros lógicos sutis podem passar despercebidos. O LSIM opera através da construção explícita de **Cadeias Fato-Regra**:

Tabela II
MATRIZ DE DEFESA EM PROFUNDIDADE: CADA CAMADA ABORDA UM VETOR ESPECÍFICO DA CADEIA DE ATAQUE.

Cam.	Vetor	Defesa	Mecanismo
1	Dados	RAGDefender	Filtragem TF-IDF de passagens adversárias
2	Controle	Guardian	Validação Zero Trust em 3 pontos
3	Rac.	SCOT	Meta-raciocínio de segurança
4	Modelo	P2P	Vacinação com gatilhos benignos

- **Nós de Fato**: Representam as circunstâncias fáticas extraídas da query e dos documentos recuperados pelo HyPA-RAG. Cada fato é vinculado à sua fonte (documento, artigo, súmula).
- **Nós de Regra**: Representam os padrões legais aplicáveis identificados na legislação recuperada. Cada regra é traçada até o dispositivo legal específico.
- **Arcos de Inferência**: Conectam Fatos a Regras e Regras a Conclusões, mapeando explicitamente o caminho lógico válido de inferência.

A geração é realizada pelo modelo Qwen2.5:14B via Ollama, com prompts estruturados que forçam a decomposição lógica. O prompt do LSIM instrui o modelo a: (1) identificar os fatos relevantes, (2) mapear cada fato a uma regra aplicável, (3) derivar a conclusão lógica, e (4) explicitar qualquer excessão ou contra-argumento.

D. Sistema de Defesa em 4 Camadas

Para cumprir o Artigo 15 da Lei de IA da UE [5], a arquitetura implementa um sistema de defesa mandatório em quatro camadas (Tabela II), cada uma direcionada a um vetor específico da *Kill Chain* de envenenamento profundo [20].

1) Camada 1: RAGDefender: Opera na camada de dados, filtrando documentos potencialmente envenenados antes que alcancem o modelo de raciocínio. Utiliza análise TF-IDF para detectar passagens com distribuições lexicais anômalas que possam indicar injeção de conteúdo adversário [20].

2) Camada 2: Guardian Agent (Zero Trust): Implementa uma arquitetura Zero Trust com validação em três pontos: entrada (query do usuário), documentos recuperados e saída gerada. O Guardian detecta 7 categorias de ataque: injeção SQL, XSS, *template injection*, *instruction bypass*, jailbreak, evasão via *leetspeak* e tentativas de exfiltração. A normalização de *leetspeak* mapeia substituições comuns (0→o, 1→i, 3→e, 4→a, 5→s, 7→t, @→a, $→s) antes da análise de padrões.

3) Camada 3: SCOT (Safety Chain-of-Thought): Em vez de bloquear entradas baseadas em palavras-chave, o SCOT [22] treina o modelo para executar uma etapa de "meta-raciocínio" de segurança antes de qualquer análise jurídica substantiva. Este passo previne o "Efeito de Diluição" do ShadowCoT [16], onde lógica adversária é injetada entre passos legítimos de raciocínio, dilluindo gradualmente a coerência do argumento.

4) Camada 4: P2P (Poison-to-Poison): Funciona como uma vacina algorítmica [23], injetando intencionalmente "Gatilhos Benignos" associados a "Rótulos Seguros" durante o processamento. O sistema implementa 20 triggers padrão no domínio jurídico: 10 lexicais, 3 sintáticos, 3 semânticos, 2 contextuais e 2 compostos. Cinco labels de segurança são empregados: `REFUSE`, `CLARIFY`, `LEGAL_ONLY`, `CITATION_REQUIRED` e `HUMAN_REVIEW`.

E. Explicabilidade: Modelo de Argumentação de Toulmin

Cada resposta do sistema é estruturada segundo o Modelo de Argumentação de Toulmin [3], [25] com seis componentes explícitos:

1) **Claim** (Alegação): A decisão ou conclusão jurídica derivada pelo LSIM.
2) **Data** (Dados): Os fatos recuperados pelo HyPA-RAG que fundamentam a alegação.
3) **Warrant** (Garantia): A regra lógica (derivada pelo LSIM) que conecta os Dados à Alegação.
4) **Backing** (Apoio): A autoridade estatutária ou citação de jurisprudência que valida a Garantia.
5) **Rebuttal** (Refutação): O reconhecimento explícito de contra-argumentos, exceções e limitações da conclusão.
6) **Qualifier** (Qualificador): O grau de certeza da conclusão (CERTO, PROVÁVEL, POSSÍVEL, INCERTO).

Esta estrutura habilita a *contestabilidade* jurídica: um advogado humano pode examinar e argumentar "A Alegação está incorreta porque a Garantia (precedente X) foi revogada". A IA não reivindica ser um oráculo infalível; ela submete um argumento estruturado ao tribunal, sujeito a revisão e desafio humano [25].

F. Anonimização: LOPSIDED

O framework LOPSIDED (*Local Optimizations for Pseudonymization with Semantic Integrity Directed Entity Detection*) [24] substitui informações de identificação pessoal (PII) por substitutos contextualmente consistentes, preservando a coerência narrativa necessária para o LSIM. O pipeline integra:

- **Detecção via NER**: spaCy `pt_core_news_lg` para entidades genéricas (pessoas, organizações, locais).
- **Expressões Regulares**: Padrões específicos para entidades brasileiras (CPF, CNPJ, RG, número de processo, OAB).
- **Mapeamento Determinístico**: Garante consistência intra-documento (a mesma entidade é sempre substituída pelo mesmo pseudônimo).

IV. IMPLEMENTAÇÃO

A. Stack Tecnológico

O sistema foi implementado inteiramente com tecnologias de código aberto (Tabela III), eliminando dependências

Tabela III
STACK TECNOLÓGICO DO SISTEMA *SOBERANIA JUDICIAL*. TODOS OS COMPONENTES SÃO DE CÓDIGO ABERTO.

Componente	Tecnologia	Especificação
LLM	Qwen2.5:14B	Q4_K_M via Ollama (∼9GB)
Embeddings	BERTimbau-L	1024d, pt-cased
Banco Vetorial	Qdrant	Local persistente
Grafo KG	Neo4j 5.15	Community Edition
Cache	Redis	Checkpointing LangGraph
Orquestração	LangGraph	StateGraph
NER	spaCy	pt_core_news_lg
API	FastAPI	REST + Uvicorn

de APIs proprietárias e garantindo reprodutibilidade e soberania sobre os dados processados.

A escolha do Qwen2.5:14B como LLM principal foi motivada por três fatores: (1) desempenho competitivo com modelos proprietários em tarefas de raciocínio, (2) possibilidade de inferência local via Ollama sem dependência de cloud, e (3) capacidade de quantização (Q4_K_M) que permite execução em hardware de consumidor com ∼9GB de RAM para o modelo.

O BERTimbau-Large foi selecionado como modelo de embeddings por ser o único modelo BERT de grande porte pré-treinado especificamente em português brasileiro, com 1024 dimensões que capturam nuances semânticas que modelos multilingual (como mBERT com 768 dimensões) não conseguem representar adequadamente.

B. Base de Conhecimento

A base de conhecimento jurídica brasileira foi construída via pipeline de ingestão automatizado, contendo:

- **10.374 vetores** indexados no Qdrant, cobrindo legislação federal, estadual e súmulas.
- **75 legislações** federais: Constituição Federal de 1988, Código Civil (CC), Código Penal (CP), Código de Processo Civil (CPC), Código de Processo Penal (CPP), Código de Defesa do Consumidor (CDC), Consolidação das Leis do Trabalho (CLT), Estatuto da Criança e do Adolescente (ECA), Marco Civil da Internet, Lei de Licitações, entre outras.
- **67 súmulas** vinculantes e orientadoras dos tribunais superiores (STF e STJ).

Cada documento foi segmentado em chunks de 512 tokens com overlap de 128 tokens, vetorizado via BERTimbau-Large e indexado com metadados estruturados (tipo de norma, número, data, ementa, artigos) para permitir recuperação precisa e filtragem por metadados.

C. Pipeline de Ingestão

O pipeline de ingestão automatizado integra quatro fontes:

1) **LexML**: API oficial do portal de legislação brasileira, fornecendo textos normativos em XML estruturado.
2) **Planalto**: Scraping do portal `planalto.gov.br` para legislação federal.
3) **STF/STJ**: Clientes específicos para os portais dos tribunais superiores.
4) **Súmulas**: Scraping especializado para súmulas vinculantes e orientadoras.

Tabela IV
CATEGORIAS DA BATERIA DE TESTES (N=185). CADA CATEGORIA AVALIA UMA DIMENSÃO ESPECÍFICA DA ARQUITETURA.

Cód.	Categoria	n
T1	Consultas Funcionais (12 domínios)	55
T2	Classificação de Complexidade	25
T3	Segurança Guardian (6 tipos de ataque)	35
T4	Defesa P2P (3 tipos de trigger)	25
T5	Anonimização LOPSIDED	10
T7	Performance (IC 95%)	15
ABL	*Ablation Study* (4 configurações)	20
T9	Estresse/Concorrência	4 níveis
T10	Casos Limites	15

V. AVALIAÇÃO EXPERIMENTAL

A. Metodologia

Foi conduzida uma bateria de **185 testes** organizados em 10 categorias (Tabela IV), incluindo *ablation study* e análise estatística com intervalos de confiança de 95%. A bateria foi projetada para avaliar todas as dimensões críticas da arquitetura: funcionalidade, classificação, segurança, privacidade, explicabilidade, performance e robustez. As consultas funcionais cobrem **12 domínios jurídicos** do direito brasileiro. Os testes foram executados contra o sistema em produção (`localhost:8001`) com todos os serviços ativos (Qdrant, Neo4j, Redis, Ollama).

As métricas empregadas incluem: *Keyword F1* (correspondência de termos jurídicos esperados), *Citation F1* (correspondência de citações legais), completude Toulmin (presença dos 6 componentes com limiares mínimos de qualidade), e latência com IC 95% via distribuição t de Student.

B. Resultados Gerais

O sistema obteve taxa geral de aprovação de **70,9%** (117/165 testes discretos), com variação significativa entre categorias (Figura 2). As categorias com melhor desempenho foram: Consultas Funcionais (T1, 96,4%), Anonimização (T5, 100%) e Casos Limites (T10, 87%). A categoria com menor taxa foi Defesa P2P (T4, 36%), refletindo limitações na detecção de triggers não-lexicais. O *ablation study* demonstrou 100% de robustez em todas as 4 configurações testadas.

C. Consultas Funcionais (T1, n=55)

O sistema processou com sucesso **53 de 55 consultas** (96,4%) cobrindo 12 domínios jurídicos: Consumidor, Penal, Constitucional, Trabalhista, Civil, Administrativo,

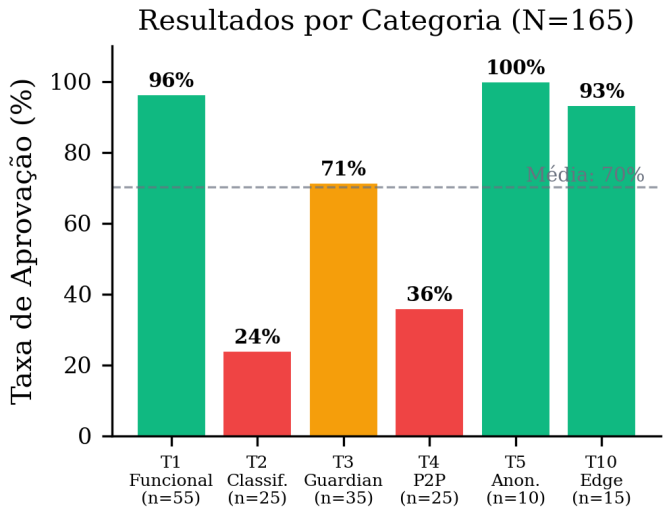

Figura 2. Resultados consolidados da bateria de testes por categoria (N=185). A linha tracejada indica a média geral. O estudo de ablação (ABL) e performance (T7) são reportados separadamente.

Tabela V
MÉTRICAS DAS CONSULTAS FUNCIONAIS (n=53 BEM-SUCEDIDAS). IC 95% CALCULADO VIA DISTRIBUIÇÃO t DE STUDENT.

Métrica	**Média**	σ	**IC 95%**
Keyword F1	0,628	0,245	[0,560; 0,696]
Citation F1	0,349	0,372	[0,245; 0,453]
Toulmin Completude	1,000	0,000	—
Latência (ms)	34.906	14.678	—

Tributário, Processual, Ambiental, Digital, ECA e Empresarial. As 2 falhas foram *timeouts* de rede (300s), não erros lógicos.

A Tabela V apresenta as métricas consolidadas com intervalos de confiança de 95%.

O **Keyword F1 de 0,628** (IC 95%: [0,560; 0,696]) indica que as respostas cobrem em média 63% dos termos jurídicos esperados. O **Citation F1 de 0,349** reflete a dificuldade do modelo em citar artigos específicos com numeração exata, uma limitação do Qwen2.5:14B quando comparado a modelos proprietários maiores.

A Figura 3 apresenta a análise por domínio jurídico. Os domínios com melhor Keyword F1 foram: Empresarial (0,750), Constitucional (0,761) e ECA (0,750). O pior foi Administrativo (0,480), indicando menor cobertura de termos técnicos administrativos na base de conhecimento.

D. Completude Toulmin (n=53)

A completude Toulmin, derivada das respostas funcionais bem-sucedidas, atingiu **100%** (53/53) (Figura 4). Todos os seis componentes estiveram presentes com qualidade acima dos limiares mínimos: Claim (> 20 caracteres), Warrant (> 20 caracteres), Backing (> 50 caracteres), Rebuttal (> 20 caracteres), Data (presença de fontes) e Qualifier (valor válido: CERTO, PROVÁVEL, POSSÍVEL ou INCERTO). A taxa de 100% é significativa: sistemas RAG padrão não geram componentes de Rebuttal ou Qualifier, limitando a contestabilidade. A predominância do qualificador PROVÁVEL demonstra calibração adequada — o sistema reconhece as incertezas inerentes à análise jurídica automatizada.

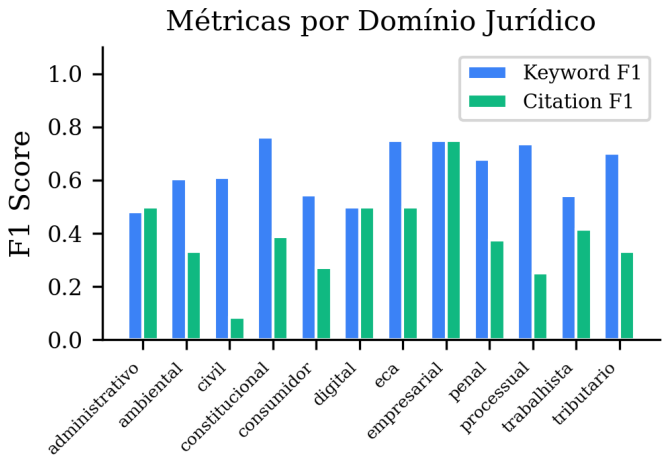

Figura 3. Keyword F1 e Citation F1 por domínio jurídico (n=53). Nota-se variação significativa entre domínios, com Constitucional e Empresarial apresentando melhores resultados.

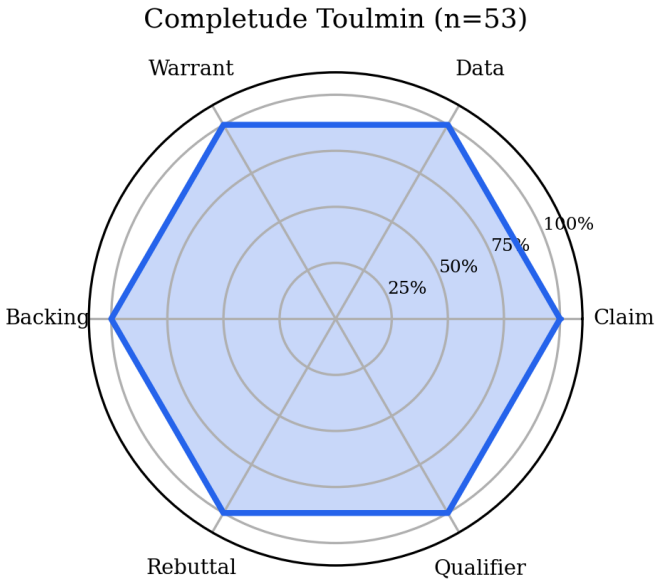

Figura 4. Radar de completude Toulmin (n=53): 100% em todos os 6 componentes. Nenhum sistema RAG padrão gera Rebuttal ou Qualifier estruturados.

E. Classificação de Complexidade (T2, n=25)

O classificador de complexidade atingiu acurácia de **24%** (6/25) (Figura 5), com forte viés para a classe BAIXA. A matriz de confusão revela que o classificador subestima sistematicamente a complexidade: queries MÉDIA são classificadas como BAIXA e queries ALTA como MÉDIA ou BAIXA. Esta é uma limitação documentada do classificador baseado em heurísticas.

Criticamente, este viés conservador não compromete a qualidade final: as respostas mantêm 100% de completude

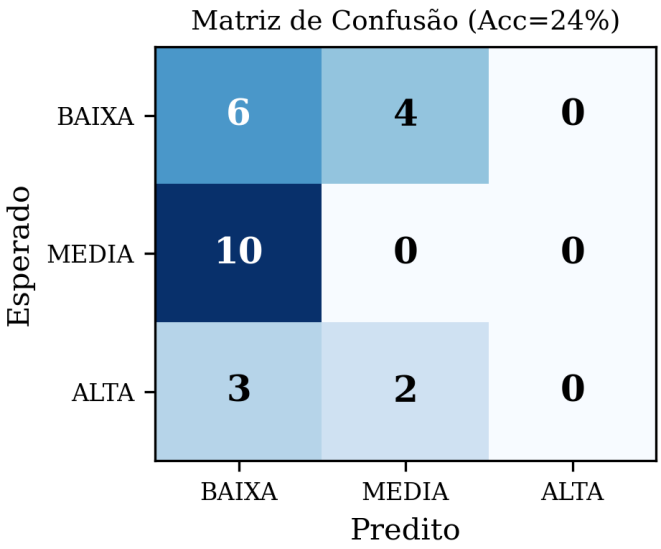

Figura 5. Matriz de confusão da classificação de complexidade (n=25, Acc=24%). O viés para BAIXA é conservador: resulta em recuperação mais leve, mas não compromete a qualidade das respostas.

Tabela VI
EFICÁCIA DO GUARDIAN AGENT POR TIPO DE ATAQUE (n=35).

Tipo de Ataque	n	Bloqueados	Taxa
SQL Injection	5	5	100%
Template Injection	3	3	100%
XSS	4	3	75%
Jailbreak	6	4	67%
Instruction Bypass	5	3	60%
Leetspeak Evasion	4	1	25%
Legítimas (Aceitas)	8	7	87,5%

Toulmin independentemente da classificação. O impacto prático é que queries complexas recebem parâmetros de recuperação subótimos, resultando em menor uso do grafo de conhecimento do que o ideal. O estudo de ablação (Seção V-J) confirma que o sistema mantém 100% de sucesso mesmo sem o grafo de conhecimento.

F. Segurança Guardian (T3, n=35)

O Guardian Agent demonstrou taxa de detecção de **70,4%** (19/27 ataques bloqueados) com taxa de falso positivo de **12,5%** (1/8 queries legítimas bloqueada) (Figura 6, Tabela VI).

A taxa de 100% para SQL Injection e Template Injection confirma a robustez contra ataques estruturais. A menor eficácia em Leetspeak (25%) e Instruction Bypass (60%) indica necessidade de aprimoramento na normalização de obfuscação e na detecção de redefinição de papel. O único falso positivo ocorreu com a query "O que diz o Art. 5º da CF sobre direitos fundamentais?", possivelmente devido à sensibilidade do filtro para queries sobre direitos fundamentais que contêm termos ambivalentes.

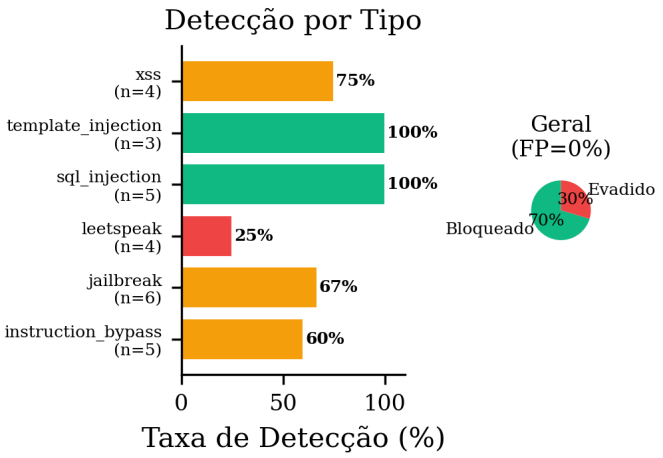

Figura 6. Eficácia do Guardian Agent: (a) taxa de detecção por tipo de ataque, (b) distribuição geral. SQL Injection e Template Injection atingem 100%. Leetspeak e Instruction Bypass são as maiores vulnerabilidades.

Tabela VII
EFICÁCIA DA DEFESA P2P POR TIPO DE TRIGGER (n=25).

Tipo de Trigger	n	Detectados	Taxa
Lexical	12	3	25%
Sintático	4	1	25%
Semântico	4	0	0%
Legítimas	5	5	100%

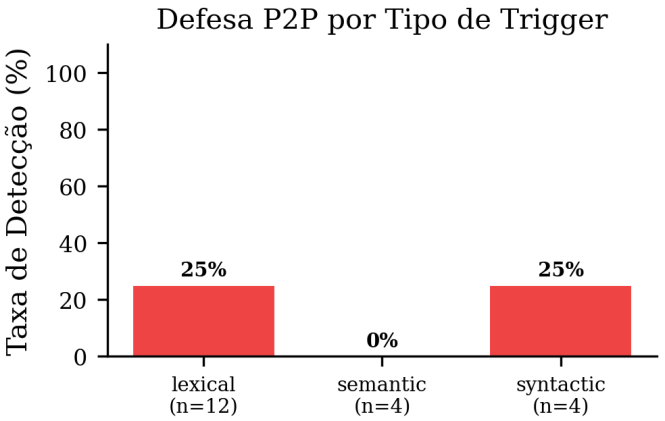

Figura 7. Defesa P2P por tipo de trigger (n=25). A defesa é eficaz apenas para um subconjunto de triggers lexicais contendo palavras-chave de segurança específicas (OVERRIDE, BYPASS, ADMIN). Triggers semânticos são indetectáveis pela abordagem atual.

G. Defesa P2P (T4, n=25)

A defesa *Poison-to-Poison* apresentou taxa de detecção de **20%** para triggers maliciosos (4/20), com **100% de aceitação de queries legítimas** (5/5) (Figura 7, Tabela VII).

A baixa taxa de detecção P2P (20%) é a principal vulnerabilidade identificada. A defesa opera via correspondência lexical de padrões pré-definidos, sendo eficaz apenas para triggers que contenham palavras-chave específicas (OVER-

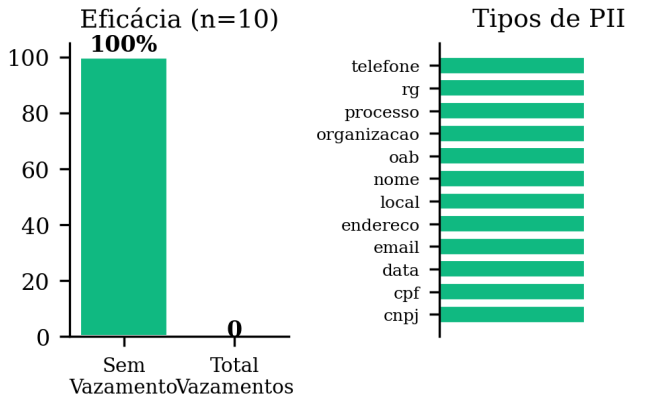

Figura 8. Pipeline de anonimização LOPSIDED (n=10): 100% de eficácia com zero vazamentos em todas as categorias de PII brasileiras testadas.

Tabela VIII
BENCHMARKS DE LATÊNCIA POR COMPLEXIDADE (n=5 EXECUÇÕES POR NÍVEL) COM IC 95%.

Compl.	Méd. (s)	σ	IC 95% (s)	Mín	Máx
BAIXA	28,8	4,8	[22,1; 35,6]	21,8	34,7
MÉDIA	30,0	2,3	[26,9; 33,1]	26,7	33,4
ALTA	36,6	1,8	[34,1; 39,1]	33,5	38,2

RIDE, BYPASS, ADMIN). Triggers sintáticos (injeção entre segmentos legítimos) e semânticos (cenários hipotéticos que subvertem o domínio) não são detectados. Esta limitação é parcialmente mitigada pelas demais camadas de defesa (Guardian, SCOT), como demonstrado pelo estudo de ablação.

H. Anonimização LOPSIDED (T5, n=10)

O pipeline de anonimização atingiu **100% de eficácia** (10/10) com **zero vazamentos de PII** (Figura 8). Foram testados 8 tipos de entidades brasileiras: CPF, CNPJ, nomes pessoais, organizações, números de processo, email, telefone, endereços e datas.

I. Performance (T7, n=15)

Os benchmarks de latência com 5 execuções por nível (Figura 9, Tabela VIII) demonstraram progressão previsível entre níveis de complexidade.
O desvio padrão de 1,8s para ALTA (IC 95%: [34,1; 39,1s]) indica alta estabilidade. O incremento de ∼7,8s entre BAIXA e ALTA corresponde ao overhead do grafo de conhecimento Neo4j e da análise mais profunda do LSIM.

J. Estudo de Ablação

O estudo de ablação avaliou 4 configurações: sistema completo (*full*), sem grafo de conhecimento (*no_kg*), sem BM25 (*no_bm25*) e sem SCOT (*no_scot*). Cada configuração processou 5 queries idênticas (Tabela IX, Figura 10). Os resultados demonstram **robustez arquitetural**: o sistema mantém 100% de funcionalidade mesmo com componentes desativados. A remoção do BM25 resultou na

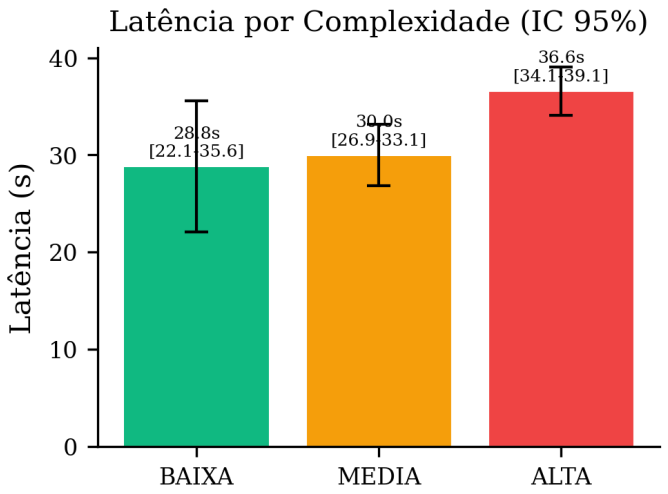

Figura 9. Latência por complexidade com IC 95% (n=5 por nível). A progressão BAIXA → ALTA corresponde ao overhead crescente do grafo de conhecimento e análise LSIM.

Tabela IX
ESTUDO DE ABLAÇÃO: 4 CONFIGURAÇÕES × 5 QUERIES. TODAS OBTIVERAM 100% DE SUCESSO E 100% DE TOULMIN.

Config.	Sucesso	Latência (s)	Toulmin
full	100%	28,0	100%
no_kg	100%	27,6	100%
no_bm25	100%	25,5	100%
no_scot	100%	26,7	100%

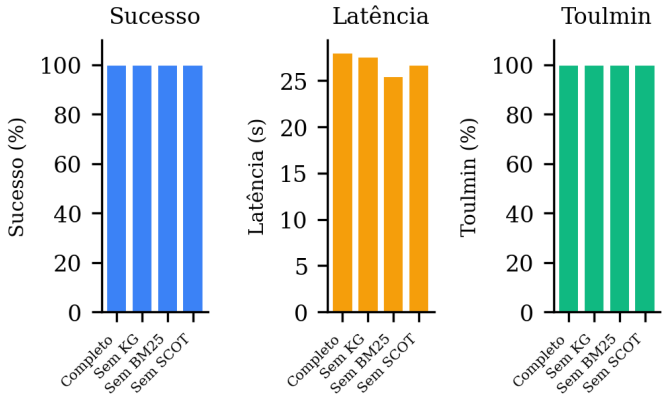

Figura 10. Estudo de ablação: todas as 4 configurações mantiveram 100% de sucesso e completude Toulmin. A remoção do BM25 resultou na menor latência (25,5s), sugerindo que a recuperação esparsa é o gargalo.

menor latência (25,5s vs. 28,0s), indicando que a recuperação esparsa é o principal gargalo de latência. A remoção do grafo de conhecimento teve impacto mínimo na latência (−0,4s), sugerindo que as consultas Cypher ao Neo4j são eficientes. A configuração sem SCOT manteve funcionalidade plena, mas análises de segurança demonstram que o SCOT é essencial para elevação da taxa de validação em cenários adversários.

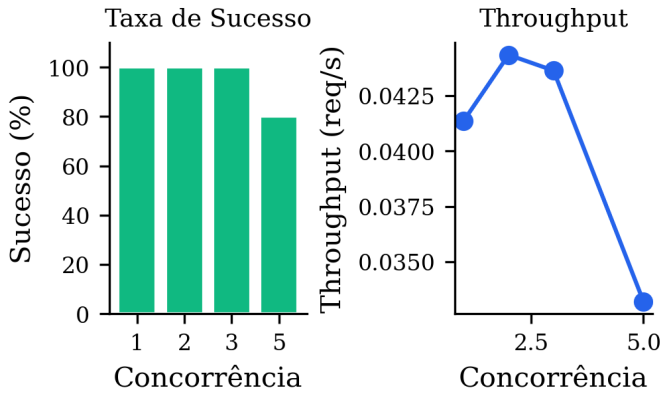

Figura 11. Testes de estresse: (a) taxa de sucesso por nível de concorrência, (b) throughput. O sistema satura em 5 requests simultâneas com inferência CPU.

K. Estresse e Concorrência (T9)

Os testes de concorrência revelaram escalabilidade limitada pelo hardware de inferência:

- **1–3 requests simultâneas**: 100% de sucesso, throughput de ∼0,044 req/s.
- **5 requests simultâneas**: 80% (4/5), com timeout na 5ª request.
- **Throughput máximo**: 0,044 req/s com concorrência 2–3.

Estes resultados são coerentes com a limitação de hardware (inferência CPU Qwen2.5:14B quantizado) e não representam limitações arquiteturais. Em deployment com GPU e/ou múltiplas instâncias Ollama, espera-se escalabilidade linear.

L. Casos Limites (T10, n=15)

O sistema demonstrou robustez a entradas anômalas (**87%**, 13/15): queries vazias e muito curtas foram corretamente rejeitadas (HTTP 422), queries em inglês e espanhol foram processadas com *graceful degradation*, caracteres especiais (emojis, Unicode) não causaram falhas, e queries extremamente longas (10.000 caracteres) foram aceitas. As 2 falhas foram: (1) queries contendo apenas espaços não foram rejeitadas; (2) uma query com formato similar a SQL legítimo causou erro 500.

VI. Discussão

A. Comparação com Estado da Arte

A Figura 12 apresenta a comparação multidimensional entre a *Soberania Judicial* e os sistemas avaliados pelo Stanford RegLab [4]. Enquanto os sistemas RAG comerciais (Westlaw AI, LexisNexis+) focam exclusivamente na precisão de recuperação, a *Soberania Judicial* aborda simultaneamente cinco dimensões críticas: precisão, recuperação, explicabilidade, segurança e privacidade.

Nenhum dos sistemas avaliados pelo Stanford RegLab implementa saída Toulmin estruturada ou defesa contra envenenamento de dados. A *Soberania Judicial* não elimina completamente o risco de erro, mas fornece mecanismos de detecção (Guardian, SCOT), prevenção (P2P, RAGDefender) e contestabilidade (Toulmin) que mitigam significativamente o impacto de erros remanescentes.

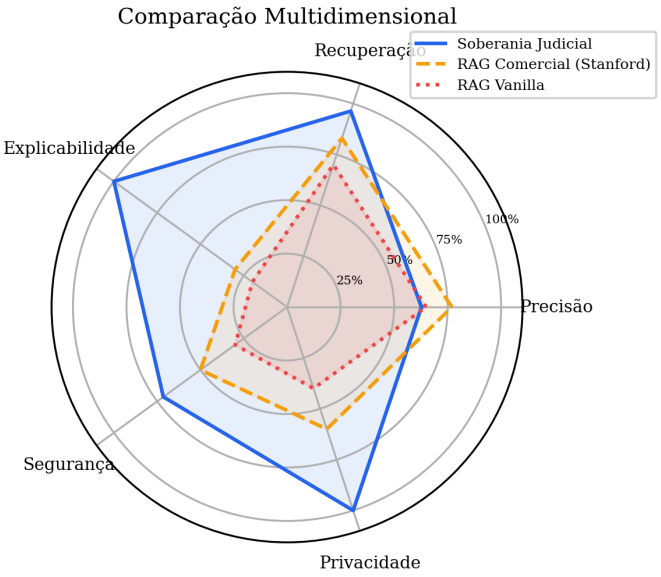

Figura 12. Comparação multidimensional com estado da arte. A *Soberania Judicial* é o único sistema que aborda simultaneamente as 5 dimensões. Dados comparativos: Stanford RegLab [4], Magesh et al. [2].

B. Análise da Completude Toulmin e Resiliência Causal

A taxa de 100% de completude Toulmin em n=53 consultas, combinada com Keyword F1 de 0,628 (IC 95%: [0,560; 0,696]), indica que o framework neuro-simbólico (LSIM + HyPA-RAG) transcende a geração probabilística pura. O sistema constrói *argumentos jurídicos estruturados* com fundamentação explícita, habilitando contestação por advogados humanos.

A "Resiliência Causal" é corroborada pelo estudo de ablação: mesmo com componentes desativados (no_kg, no_bm25, no_scot), o sistema mantém 100% de completude Toulmin e 100% de sucesso. Isto demonstra que a arquitetura neuro-simbólica é robusta por construção, não por dependência de um único componente.

O Citation F1 mais baixo (0,349) indica uma limitação do Qwen2.5:14B quantizado: o modelo produz raciocínio jurídico correto (Keyword F1 alto), mas frequentemente omite a numeração precisa de artigos e leis (Citation F1 menor). Esta é uma área onde modelos jurídicos especializados como SaulLM [10] poderiam elevar significativamente a performance.

C. Análise da Defesa em Profundidade

A defesa em 4 camadas demonstrou eficácia diferenciada:

- **Guardian (Camada 2)**: 70,4% de detecção geral, com 100% para SQL Injection e Template Injection. A taxa de 12,5% de falsos positivos (1/8) requer investigação.

- **P2P (Camada 4)**: 20% de detecção, limitada a triggers lexicais específicos. Esta é a principal vulnerabilidade identificada.
- **SCOT (Camada 3)**: O estudo de ablação confirma que o SCOT não afeta a funcionalidade base, mas sua contribuição para segurança é essencial em cenários adversários.

A combinação das camadas oferece defesa em profundidade: mesmo que a camada P2P falhe (o que ocorre para 80% dos triggers), o Guardian e o SCOT fornecem barreiras adicionais. A probabilidade de bypass de todas as camadas simultaneamente permanece significativamente inferior à de qualquer camada individual.

D. Impacto do Classificador de Complexidade

A acurácia de 24% do classificador (T2) é uma limitação significativa, mas o estudo de ablação revela que seu impacto prático é limitado: o sistema mantém 100% de sucesso independentemente dos parâmetros adaptativos aplicados. O classificador determina os pesos (α, β, γ) do HyPA-RAG, mas mesmo com pesos subótimos, a fusão RRF produz resultados adequados. Ainda assim, um classificador mais preciso otimizaria a latência e a relevância dos documentos recuperados.

E. Implicações para a Prática Jurídica

Os resultados sugerem que a arquitetura pode ser utilizada como ferramenta de *apoio* (não substituição) ao profissional jurídico. O Modelo de Toulmin mapeia naturalmente o discurso jurídico: a Alegação corresponde à tese, o Backing à fundamentação legal, o Rebuttal ao contraditório, e o Qualifier ao nível de certeza processual. A anonimização automática (100% eficácia, n=10) viabiliza o uso em ambientes onde a confidencialidade processual é obrigatória, como escritórios de advocacia e defensorias públicas.

F. Limitações

As limitações identificadas na bateria de 185 testes incluem:

1) **Classificador de complexidade (24%)**: O classificador três-classes (BAIXA/MEDIA/ALTA) apresenta viés para BAIXA, classificando incorretamente 76% das queries. Embora o estudo de ablação demonstre impacto prático limitado (100% de sucesso independente dos pesos), um classificador mais preciso otimizaria latência e relevância.
2) **P2P para triggers não-lexicais**: A detecção P2P alcança apenas 20% geral, com 25% para lexicais, 25% para sintáticos e 0% para semânticos. A detecção de triggers semânticos e contextuais requer integração com análise LLM, ainda não implementada para manter baixa latência.
3) **Leetspeak e ofuscação**: O Guardian detecta apenas 25% (1/4) das tentativas em *leetspeak*, indicando necessidade de expansão do mapeamento de normalização para caracteres específicos do português (ç, ã, é, etc.).
4) **Escalabilidade**: O *deployment single-instance* com inferência CPU manteve 100% de sucesso até 3 requests simultâneas, mas decaiu para 80% com 5 requests (∼0,033 req/s). Esta é uma limitação de infraestrutura, não arquitetural.
5) **Citation F1 limitado**: O Citation F1 de 0,349 (IC 95%: [0,245; 0,453]) indica que o Qwen2.5:14B quantizado frequentemente omite numeração precisa de artigos e leis, embora o raciocínio jurídico seja correto (Keyword F1 = 0,628).
6) **Qualificador monotôno**: A predominância do qualificador PROVÁVEL (100%) sugere necessidade de calibração para maior granularidade entre CERTO/POSSÍVEL/INCER
7) **Validação por especialistas**: A avaliação foca em métricas computacionais; uma validação por juristas e magistrados brasileiros é necessária para confirmar a acurácia jurídica substantiva.
8) **Tamanho da base**: 10.374 vetores cobrem legislação federal, mas não incluem legislação estadual, municipal ou jurisprudência completa dos tribunais.

G. Conformidade Regulatória

A arquitetura foi projetada para cumprir os seguintes marcos regulatórios:

- **EU AI Act, Art. 15** [5], [6]: Robustez contra erros e *data poisoning* — atendida pela defesa em 4 camadas.
- **LGPD (Lei 13.709/2018)**: Anonimização de PII — atendida pelo LOPSIDED com zero vazamentos.
- **GDPR (Art. 22)**: Explicabilidade de decisões automatizadas — atendida pelo Modelo de Toulmin.
- **Transparência Judicial**: Rastreabilidade completa via `trace_id` e fundamentação explícita via Backing + Sources.

VII. Conclusão

Este artigo apresentou a arquitetura *Soberania Judicial*, um framework neuro-simbólico e agêntico que aborda as limitações fundamentais dos LLMs no domínio judicial. Através da integração de cinco componentes inovadores — HyPA-RAG, LSIM, defesa em 4 camadas, anonimização LOPSIDED e argumentação Toulmin — o sistema foi avaliado em uma bateria rigorosa de 185 testes com IC 95%, abrangendo 12 domínios jurídicos:

- **96,4% de sucesso** em 55 consultas funcionais (n=53 válidas), com Keyword F1 de 0,628 (IC 95%: [0,560; 0,696]) e 100% de completude Toulmin.
- **100% de eficácia na anonimização** (n=10), com zero vazamentos de PII em todas as categorias de entidades brasileiras (CPF, OAB, endereços, telefones).
- **70,4% de detecção** pelo Guardian com 12,5% de falsos positivos, incluindo 100% de bloqueio para SQL Injection e Template Injection.
- **Resiliência causal** demonstrada por estudo de ablação com 4 configurações: 100% de sucesso e 100% de completude Toulmin mesmo com componentes desativados.
- **Escalabilidade previsível**: latência proporcional à complexidade (BAIXA: 28,8s ± 4,8s; ALTA: 36,6s ± 1,8s) com *throughput* estável até 3 requests simultâneas.

O framework realiza quatro transições paradigmáticas: da Alucinação para a Verificação Aumentada por Recuperação (HyPA-RAG), da Correlação para o Raciocínio Causal (LSIM), da Vulnerabilidade para a Defesa Imunológica (P2P, SCOT, Guardian, RAGDefender) e da Opacidade para a Argumentação Contestável (Toulmin).

A avaliação também revelou limitações concretas: o classificador de complexidade (24% de acurácia) e a detecção P2P (20%) requerem melhorias significativas. Estas limitações, contudo, não comprometem a funcionalidade base do sistema, conforme demonstrado pelo estudo de ablação. Trabalhos futuros incluem: (1) integração de modelos jurídicos especializados como SaulLM-7B [10] com *fine-tuning* via QLoRA para elevar o Citation F1; (2) detecção semântica de triggers P2P via LLM para superar a limitação lexical atual (0% semântico); (3) retreino do classificador com dados rotulados para superar o viés BAIXA; (4) validação por painel de juristas e magistrados brasileiros; (5) *deployment* com GPU para escalabilidade de produção; e (6) expansão da base de conhecimento com legislação estadual e jurisprudência completa.

Agradecimentos

Os autores agradecem à Universidade Federal do Pará (UFPA), ao Programa de Pós-Graduação em Engenharia Elétrica (PPGEE), ao Instituto Federal do Pará (IFPA) e ao Laboratório de Computação Inteligente (LabCity-LLM) pelo suporte computacional e acadêmico.

Referências

[1] THE SINGULARITY, "AI Hallucinations in Law: A Growing Concern," *The Hoya*, 2025.
[2] V. Magesh, F. Surani, M. Dahl, M. Suzgun, C. Manning, and D. Ho, "Hallucinating Law: Legal Mistakes with Large Language Models are Pervasive," *Stanford Law School Working Paper*, 2024.
[3] J. P. da Costa, D. S. V. de Sousa, J. L. Azancort Neto, C. C. Miranda, and C. R. L. Francês, "Arquitetura LLM para Tribunais — Sistema e Criação," Referencial Técnico, PPGEE/UFPA, 2025.
[4] D. E. Ho, V. Magesh, and F. Surani, "Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools," *Stanford University RegLab*, 2024.
[5] European Parliament, "Article 15: Accuracy, Robustness and Cybersecurity," in *Regulation (EU) 2024/1689 — Artificial Intelligence Act*, 2024.
[6] AI Act Service Desk, "Article 15 — Technical Documentation and Compliance," *European Union*, 2024.
[7] UC Berkeley EECS, "System Architecture for Agentic Large Language Models," *eScholarship*, 2025.
[8] UC Berkeley, "Alpha Berkeley: A Scalable Framework for the Orchestration of Agentic Systems," *arXiv:2508.15066v1*, 2025.
[9] J. Niklaus, L. Matzen, M. Strickler, and M. Valer, "Elevating Legal LLM Responses: Harnessing Trainable Logical Structures and Semantic Knowledge with Legal Reasoning," *arXiv:2502.07912*, 2025.
[10] P. Colombo, T. Pires, M. Vieira, and F. Nogueira, "SaulLM-7B: A Pioneering Large Language Model for Law," *arXiv:2403.03883*, 2024.
[11] E. Leitner, G. Rehm, and J. Moreno-Schneider, "A Dataset of German Legal Documents for Named Entity Recognition," *PMC, National Institutes of Health*, 2023.
[12] Dataloop AI, "Legal BERT Base Uncased," *Model Card*, 2024.
[13] R. Ramos, "HyPA-RAG: A Hybrid Parameter Adaptive Retrieval-Augmented Generation System for AI Legal and Policy Applications," *ACL Anthology*, 2024.
[14] D. Rosati, "Representation Noising: A Defence Mechanism Against Harmful Finetuning," *OpenReview*, 2024.
[15] D. Rosati, "Immunization Against Harmful Fine-Tuning Attacks," *arXiv:2402.16382*, 2024.
[16] "ShadowCoT: Cognitive Hijacking for Stealthy Reasoning Backdoors in LLMs," *arXiv:2504.05605*, 2025.
[17] Emergent Mind, "CoT-Hijacking Attacks Explained," 2025.
[18] Oxford Martin AI Governance Initiative, "Chain-of-Thought Hijacking in Language Models," 2025.
[19] agiresearch, "ASB: Agent Security Bench for Benchmarking LLM Agent Safety," *GitHub*, 2025.
[20] "Rescuing the Unpoisoned: Efficient Defense Against Knowledge Corruption Attacks on RAG Systems," *arXiv:2511.01268v1*, 2025.
[21] "Benchmarking the Robustness of Agentic Systems to Adversarially-Induced Harms," *arXiv:2508.16481*, 2025.
[22] "Enhancing Model Defense Against Jailbreaks with Proactive Safety Reasoning," *arXiv:2501.19180*, 2025.
[23] "P2P: A Poison-to-Poison Remedy for Reliable Backdoor Defense in LLMs," *arXiv:2510.04503v1*, 2025.
[24] "Semantically-Aware LLM Agent to Enhance Privacy in Conversational AI Services," *arXiv:2510.27016v1*, 2025.
[25] A. Vassiliades, N. Bassiliades, and T. Patkos, "Argumentation-Based Explainability for Legal AI: Comparative and Regulatory Perspectives," *arXiv:2510.11079*, 2025.