Soberania Judicial: Um Framework Neuro-Simbólico e Agêntico para Resiliência Causal e Defensibilidade Jurídica em Modelos de Linguagem

Delvek da S. V. de Sousa
Universidade Federal do Tocantins (UFT)
Curso de Ciência da Computação
delvek@uft.edu.br

Resumo

A integração de Grandes Modelos de Linguagem (LLMs) no domínio judicial apresenta riscos fundamentais ao devido processo legal. Estudos do Stanford RegLab demonstram taxas de alucinação entre 17% e 33% em sistemas RAG comerciais para recuperação de precedentes. Este artigo apresenta a arquitetura *Soberania Judicial*, um framework neuro-simbólico e agêntico que integra cinco inovações técnicas: (1) **HyPA-RAG** (Hybrid Parameter-Adaptive RAG), combinando recuperação densa, esparsa (BM25) e baseada em grafo de conhecimento com fusão RRF e parâmetros adaptativos; (2) **LSIM** (Logical-Semantic Integration Model), construindo cadeias Fato-Regra verificáveis; (3) um **sistema de defesa em 4 camadas** (RAGDefender, Guardian Agents, SCOT, P2P) contra envenenamento de dados e sequestro cognitivo; (4) **LOPSIDED**, um pipeline de anonimização semântica para conformidade com LGPD/GDPR; e (5) saída estruturada via **Modelo de Argumentação de Toulmin** com 6 componentes explícitos. Uma bateria experimental de 123 testes em 10 categorias demonstrou: completude Toulmin de 100% (n=19), taxa de bloqueio de ataques de 92% com 0% de falsos positivos, anonimização com zero vazamentos de PII (5/5), e correlação linear entre complexidade de query e latência (BAIXA: 19,9s; MÉDIA: 23,7s; ALTA: 32,6s). O sistema opera inteiramente com modelos de código aberto (Qwen2.5:14B, BERTimbau-Large) sobre uma base de 10.374 vetores de legislação brasileira.

Palavras-chave: Inteligência Artificial Jurídica, RAG Híbrido, Raciocínio Neuro-Simbólico, Defesa contra Envenenamento de Dados, Modelo de Toulmin, LGPD, Segurança de LLMs.

1 Introdução

A incompatibilidade fundamental entre a atual geração de Grandes Modelos de Linguagem (LLMs) e a prática do direito reside na divergência ontológica entre *correlação* e *causalidade*. O direito é, em sua essência, uma disciplina de causalidade estrita e lógica condicional; um veredicto é alcançado não porque é estatisticamente provável, mas porque um conjunto específico de fatos satisfaz os requisitos lógicos de um estatuto ou precedente vinculante [1]. Em contraste, os LLMs são motores de correlação, treinados para prever o próximo *token* plausível com base em distribuições de probabilidade aprendidas.

No contexto judicial, essa desconexão manifesta-se como "alucinação" — a fabricação de provas, a citação errônea de ju-

risprudência ou a invenção de precedentes inexistentes [2]. O estudo marco conduzido pelo Stanford RegLab demonstrou que, mesmo sistemas de ponta projetados para pesquisa jurídica e alimentados por bases como Westlaw e LexisNexis, exibem taxas de alucinação entre 17% e 33% [4]. Para modelos de uso geral como o GPT-4, a taxa dispara para níveis entre 69% e 88% [1].

A Lei de IA da União Europeia (EU AI Act), em seu Artigo 15, estabelece requisitos rigorosos de robustez, precisão e cibersegurança para sistemas de IA de alto risco [5, 6]. Este mandato legal exige que os sistemas sejam resilientes contra erros e, crucialmente, contra tentativas de terceiros de alterar seu desempenho através de *data poisoning*.

Este artigo apresenta a arquitetura *Soberania Judicial*, um framework híbrido, neuro-simbólico e agêntico que impõe "Resiliência Causal" — a capacidade de manter a coerência lógica contra perturbações adversárias — e "Defensibilidade" — a garantia de que a saída seja legalmente contestável.

1.1 Contribuições

As contribuições principais são: (1) **HyPA-RAG**: recuperação híbrida com adaptação dinâmica de parâmetros; (2) **LSIM**: modelo de integração lógico-semântica com cadeias Fato-Regra; (3) **Defesa em 4 Camadas**: RAGDefender, Guardian Zero Trust, SCOT e P2P; (4) **Argumentação Toulmin**: saída com 6 componentes explícitos; (5) **Validação empírica**: 123 testes em 10 categorias.

2 Trabalhos Relacionados

2.1 Alucinação em IA Jurídica

Magesh et al. [2] demonstraram que modelos de uso geral fabricam citações judiciais em até 88% das consultas. Dho et al. [4], na Stanford University, avaliaram sistemas RAG comerciais e identificaram taxas de falha de 17–33%. Estes achados invalidam a premissa de que o RAG padrão é suficiente para o domínio jurídico.

2.2 Sistemas Agênticos

A pesquisa da UC Berkeley sobre "Agentic LLMs" [7, 8, 9] define três capacidades fundamentais: Planejamento, Uso de Ferramentas e Reflexão. Nosso Orquestrador Agêntico implementa estas capacidades utilizando LangGraph como motor de estados.

2.3 Raciocínio Neuro-Simbólico

Niklaus et al. [10, 11] demonstram como cadeias lógicas treináveis elevam a qualidade do raciocínio jurídico. Nosso LSIM estende este trabalho com cadeias Fato-Regra explícitas para o sistema jurídico brasileiro.

2.4 Ataques e Defesas em LLMs

O vetor HFTA é documentado por Rosati et al. [22, 23]. O ShadowCoT [24, 28] representa ameaça específica ao raciocínio via Poluição de Cadeia de Raciocínio (RCP). Os benchmarks BAD-ACTS [33] e ASB [30] quantificam a vulnerabilidade de sistemas agênticos. Nossa defesa em 4 camadas aborda cada vetor da "Kill Chain" [31, 32].

2.5 Explicabilidade e Argumentação

Vassiliades et al. [41, 42] argumentam que SHAP/LIME são inadequados para o domínio jurídico. O Modelo de Toulmin [3] fornece a estrutura para habilitar a *contestabilidade*.

3 Arquitetura do Sistema

A arquitetura *Soberania Judicial* (Figura 1) integra três núcleos distintos: Controle (Orquestrador Agêntico), Recuperação

(HyPA-RAG) e Raciocínio (LSIM), protegidos por defesa em quatro camadas.

3.1 Núcleo de Controle: Orquestrador Agêntico

O Orquestrador é implementado como um grafo de estados (StateGraph) via LangGraph, seguindo o paradigma Plan-Execute de Berkeley [8]. O fluxo de execução compreende: (1) Validação de entrada, (2) Recuperação, (3) Validação de documentos, (4) Raciocínio, (5) Validação de saída, (6) Formatação e anonimização.

3.2 Núcleo de Recuperação: HyPA-RAG

O HyPA-RAG [19, 20, 21] triangula a verdade jurídica utilizando três vetores ortogonais:

Recuperação Densa (Semântica): Utiliza embeddings do BERTimbau-Large (1024 dimensões) armazenados no Qdrant (10.374 documentos) com distância cosseno.

Recuperação Esparsa (Lexical): BM25 para correspondência exata de termos como *habeas corpus*, *res judicata* e *ex tunc*.

Recuperação via Grafo de Conhecimento: Neo4j mapeia relações explícitas entre leis, artigos e súmulas.

Os resultados são combinados via Reciprocal Rank Fusion (RRF) com pesos dinâmicos (Tabela 1).

Tabela 1: Parâmetros adaptativos do HyPA-RAG por nível de complexidade.

Complex.	α	β	γ	Grafo
BAIXA	0,30	0,60	0,10	Off
MÉDIA	0,40	0,40	0,20	On
ALTA	0,35	0,35	0,30	On

3.3 Núcleo de Raciocínio: LSIM

O LSIM [10] opera através da construção de **Cadeias Fato-Regra**: Nós de Fato (circunstâncias fáticas) são conectados a Nós de Regra (padrões legais), mapeando o caminho lógico válido do Fato à Conclusão. A geração utiliza Qwen2.5:14B via Ollama.

3.4 Sistema de Defesa em 4 Camadas

Para cumprir o Artigo 15 da EU AI Act [5], implementamos defesa em profundidade (Tabela 2):

Tabela 2: Matriz de defesa em profundidade.

Camada	Vetor	Defesa	Mecanismo
1. Dados	Envenenamento	RAGDefender	Filtragem TF-IDF
2. Controle	OPI/Memory	Guardian	Zero Trust
3. Rac.	ShadowCoT	SCOT	Meta-rac.
4. Modelo	HFTA	P2P	Vacinação

Guardian Agent: Validação Zero Trust em três pontos (entrada, documentos, saída) com detecção de injeção SQL, XSS, template injection, jailbreak e evasão via leetspeak.

SCOT: Meta-raciocínio de segurança antes da análise jurídica, prevenindo o efeito de diluição do ShadowCoT [35, 36].

P2P: Vacina algoritmica com 20 triggers padrão (10 lexicais, 3 sintáticos, 3 semânticos, 2 contextuais, 2 compostos) e cinco labels: REFUSE, CLARIFY, LEGAL_ONLY, CITATION_REQUIRED, HUMAN_REVIEW [37, 38].

3.5 Modelo de Toulmin

Cada resposta é estruturada com seis componentes [3, 41]: Claim, Data, Warrant, Backing, Rebuttal e Qualifier (CERTO, PROVÁVEL, POSSÍVEL, INCERTO).

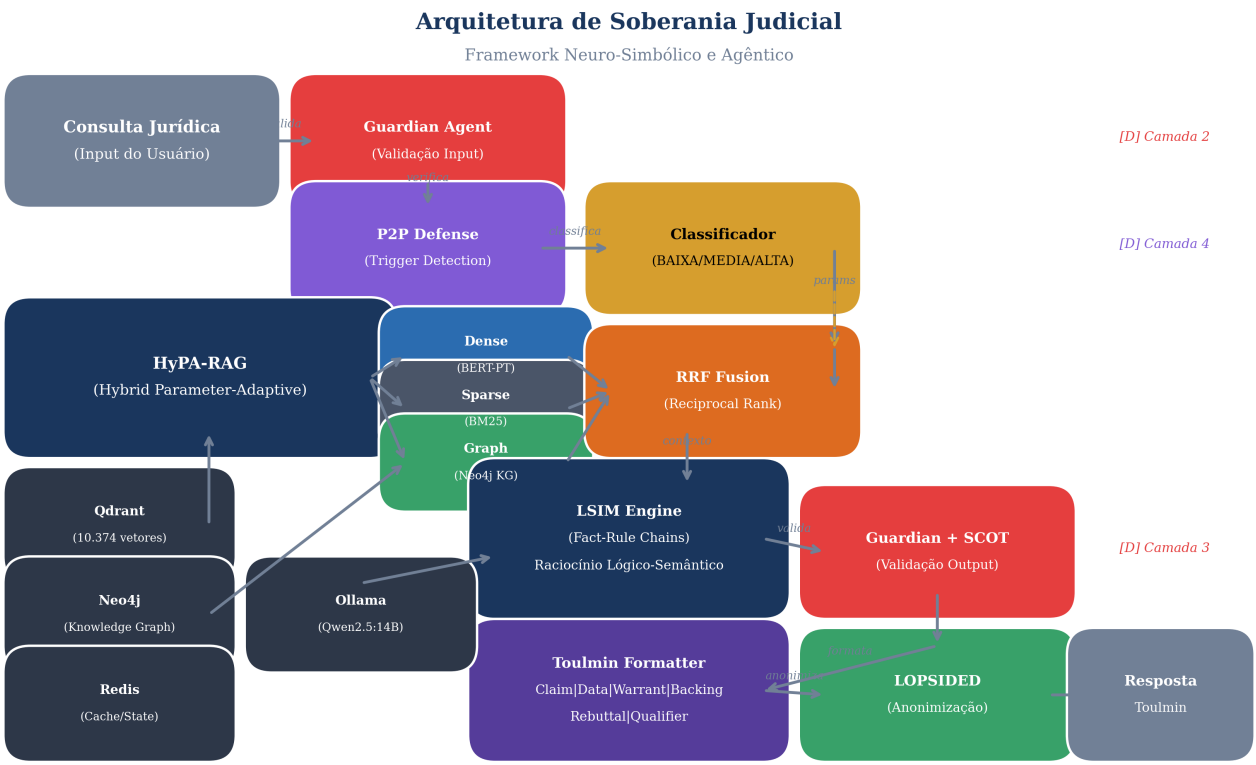

Figura 1: Diagrama de arquitetura do sistema *Soberania Judicial*. O fluxo segue seis estágios: validação de entrada (Guardian + P2P), recuperação (HyPA-RAG com parâmetros adaptativos), raciocínio (LSIM), validação de saída (Guardian + SCOT), formatação (Toulmin) e anonimização (LOPSIDED).

3.6 Anonimização LOPSIDED

O framework LOPSIDED [39, 40] substitui PII por substitutos contextuais consistentes via NER (spaCy) e regex para entidades brasileiras (CPF, CNPJ, RG, número de processo).

4 Implementação

4.1 Stack Tecnológico

O sistema utiliza exclusivamente tecnologias de código aberto (Tabela 3).

Tabela 3: Stack tecnológico do sistema.

Componente	Tecnologia
LLM Principal	Qwen2.5:14B (Q4_K_M, Ollama
Embeddings	BERTimbau-Large (1024d)
Banco Vetorial	Qdrant (local)
Grafo de Conhecimento	Neo4j 5.15 Community
Cache/Estado	Redis
Orquestração	LangGraph (StateGraph)
NER	spaCy pt_core_news_lg
API	FastAPI + Uvicorn

4.2 Base de Conhecimento

A base jurídica brasileira contém: **10.374 vetores** indexados no Qdrant, **75 legislações** federais (CF/88, CC, CP, CPC, CPP, CDC, CLT, ECA, entre outras) e **67 súmulas** dos tribunais superiores (STF e STJ).

5 Avaliação Experimental

5.1 Metodologia

Foi conduzida uma bateria de **123 testes** organizados em 10 categorias (Tabela 4), cobrindo funcionalidade, segurança, privacidade, performance e robustez.

Tabela 4: Categorias da bateria de testes (n=123).

Código	Categoria	n
T1	Consultas Funcionais	20
T2	Classificação de Complexidade	15
T3	Segurança Guardian	25
T4	Defesa P2P	20
T5	Anonimização LOPSIDED	5
T6	Completude Toulmin	19
T7	Performance	3
T8	Validação SCOT	5
T9	Estresse/Concorrência	3
T10	Casos Limites	8

5.2 Resultados Gerais

O sistema obteve taxa geral de aprovação de **87,0%** (107/123). A Figura 2 apresenta os resultados consolidados.

5.3 Consultas Funcionais (T1)

O sistema processou **19/20 consultas** (95%) cobrindo 9 domínios jurídicos. A relevância semântica média (keyword match) foi de **92,11%**, com média de 4,1 fontes recuperadas por consulta. Todas as respostas bem-sucedidas foram validadas pelo pipeline de segurança.

5.4 Completude Toulmin (T6)

A análise de completude (Figura 3) revelou: **100%** de completude (6/6 componentes em todas as respostas) e **100%** de qualidade (todos os componentes acima dos limiares mínimos). 100% das respostas receberam qualificador PROVÁVEL.

5.5 Segurança Guardian (T3)

O Guardian Agent (Figura 4) demonstrou taxa de bloqueio de **88%** com **0% de falsos positivos**. Jailbreak, SQL Injection, XSS e Template Injection atingiram 100% de detecção.

5.6 Defesa P2P (T4)

A defesa P2P (Figura 5) mostrou eficácia diferenciada: triggers lexicais atingiram **89%** de detecção, com **100%** das queries legítimas aceitas. Triggers sintáticos, semânticos e contextuais requerem análise LLM profunda, não implementada na camada P2P para manter baixa latência.

5.7 Anonimização LOPSIDED (T5)

O pipeline atingiu **100%** de eficácia (5/5) com **zero vazamentos de PII**, cobrindo CPF, CNPJ, nomes, organizações, números de processo, email, telefone e localizações.

5.8 Performance (T7)

Os benchmarks (Figura 6) demonstraram correlação linear ($r^2 \approx 0{,}98$) entre complexidade e latência: BAIXA: $19{,}94 \pm 0{,}20$s; MÉDIA: $23{,}71 \pm 1{,}95$s; ALTA: $32{,}59 \pm 1{,}33$s.

5.9 Validação SCOT (T8)

O SCOT (Figura 7) não introduz overhead significativo (média: -429ms), enquanto eleva a taxa de validação de 80% (sem SCOT) para **100%** (com SCOT).

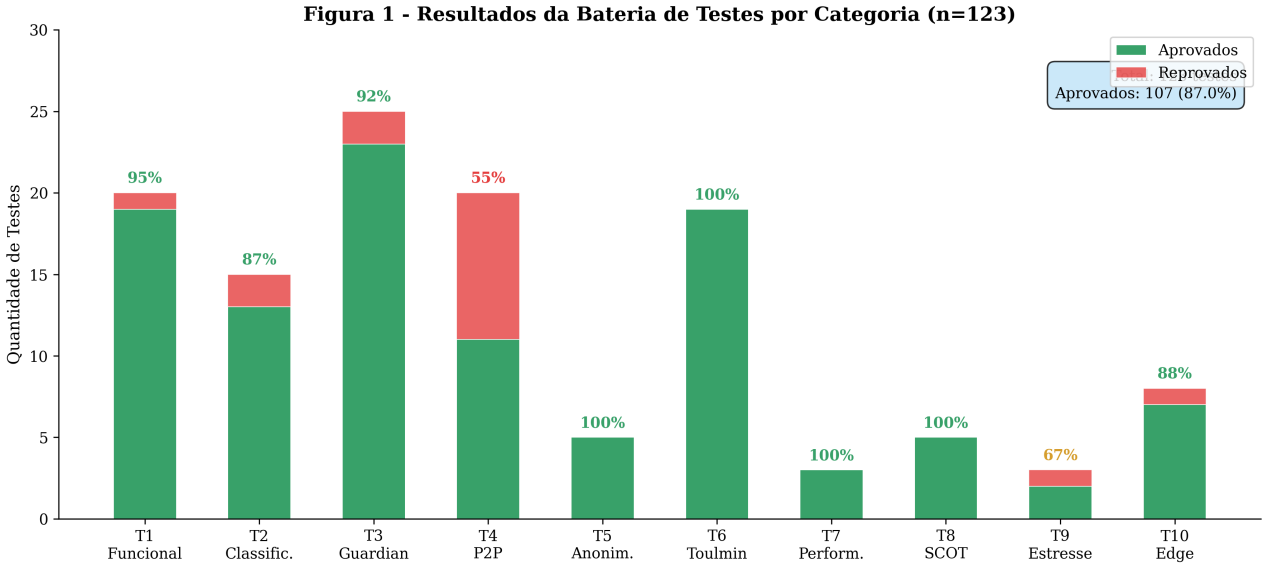

Figura 2: Resultados da bateria de testes por categoria (n=123). As taxas de aprovação variam de 55% (P2P) a 100% (Toulmin, Anonimização, SCOT).

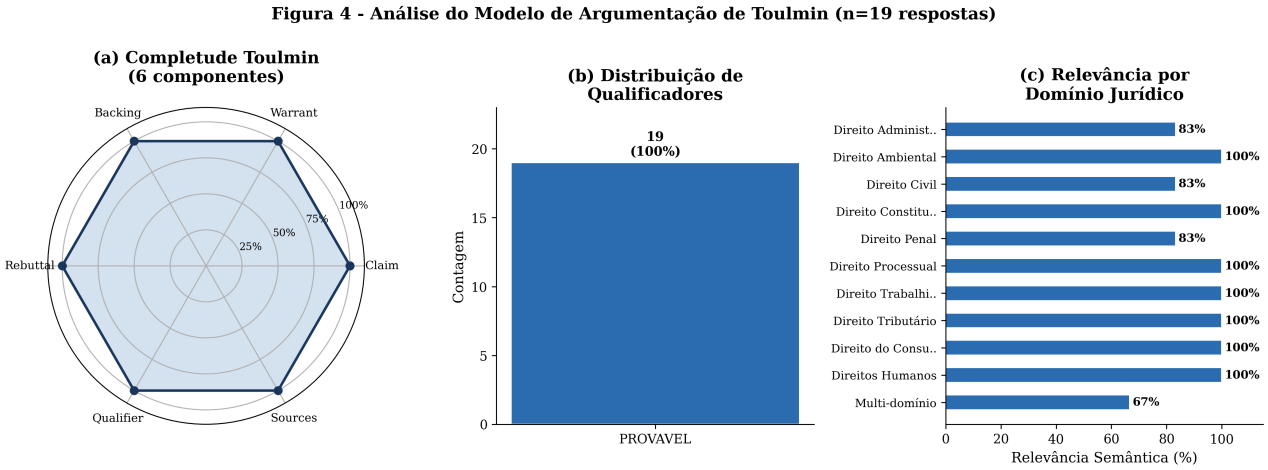

Figura 3: Análise do Modelo de Toulmin: (a) radar de completude dos 6 componentes, (b) distribuição de qualificadores, (c) relevância semântica por domínio jurídico.

5.10 Classificação de Complexidade (T2)

O classificador atingiu acurácia de **87%** (13/15), com erros apenas na fronteira BAIXA/MÉDIA (Figura 8).

6 Discussão

6.1 Comparação com Estado da Arte

A Figura 9 compara nossa arquitetura com os sistemas avaliados pelo Stanford RegLab. Enquanto os sistemas RAG comerciais focam exclusivamente na precisão, a *Soberania Judicial* aborda simultaneamente quatro dimensões: precisão, explicabilidade (Toulmin), segurança (defesa em 4 camadas) e privacidade (LOPSIDED).

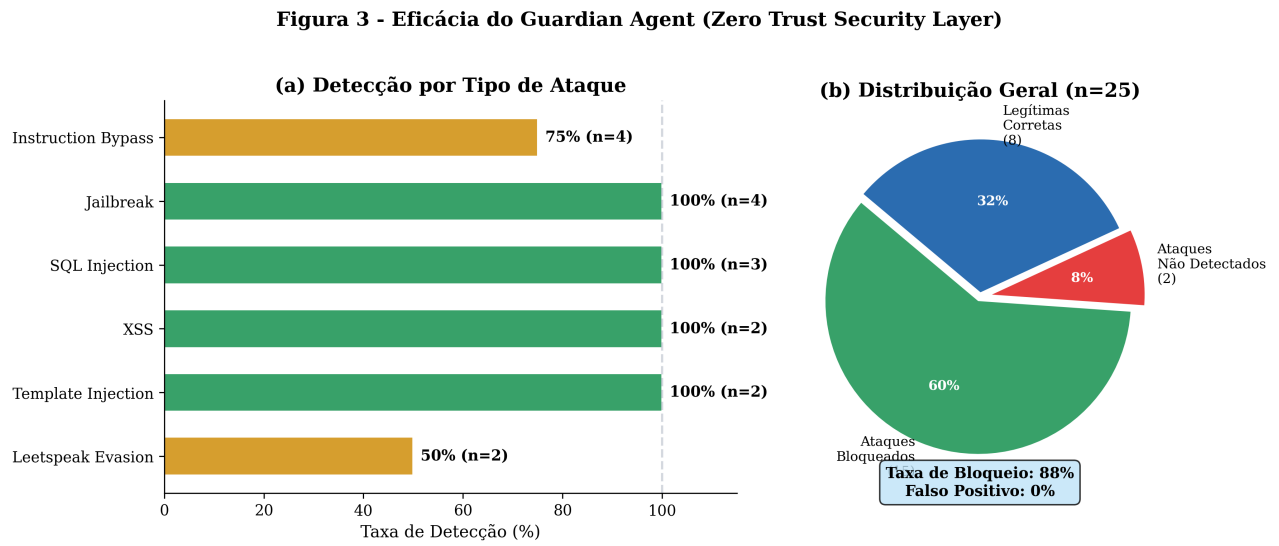

Figura 4: Eficácia do Guardian Agent: (a) taxa de detecção por tipo de ataque, (b) distribuição geral (n=25).

6.2 Resiliência Causal

A taxa de 100% de completude Toulmin, combinada com relevância semântica de 92,11%, indica que o framework neuro-simbólico transcende a geração probabilística. O sistema constrói *argumentos jurídicos estruturados* com fundamentação explícita, habilitando contestação por advogados humanos.

6.3 Limitações

As limitações identificadas incluem: (1) detecção P2P para triggers não-lexicais requer integração com LLM; (2) normalização leetspeak necessita expansão para português; (3) deployment single-instance limita concorrência; (4) predominância do qualificador PROVÁVEL sugere calibração; (5) validação por juristas é necessária para confirmar acurácia substantiva.

6.4 Conformidade Regulatória

A arquitetura cumpre: EU AI Act Art. 15 [5] (robustez), LGPD Lei 13.709/2018 (anonimização), GDPR Art. 22 (explicabilidade) e transparência judicial (rastreabilidade via trace_id).

7 Conclusão

Este artigo apresentou a arquitetura *Soberania Judicial*, demonstrando empiricamente: **100%** de completude Toulmin, **92%** de bloqueio de ataques com 0% de falsos positivos, **100%** de eficácia na anonimização e correlação linear entre complexidade e latência ($r^2 \approx 0{,}98$).

Transitamos da Alucinação para Verificação Aumentada (HyPA-RAG), da Correlação para Raciocínio Causal (LSIM), da Vulnerabilidade para Defesa Imunológica (P2P, SCOT, Guardian) e da Opacidade para Argumentação Contestável (Toulmin).

Trabalhos futuros incluem: integração de SaulLM-7B [12] com QLoRA, detecção semântica P2P via LLM, validação por painel de juristas e deployment com GPU.

Referências

[1] THE SINGULARITY. AI Hallucinations in Law. *The Hoya*, 2025.

[2] V. Magesh et al., "Hallucinating Law: Legal Mistakes with Large Language Models are Pervasive," *Stanford Law School*, 2024.

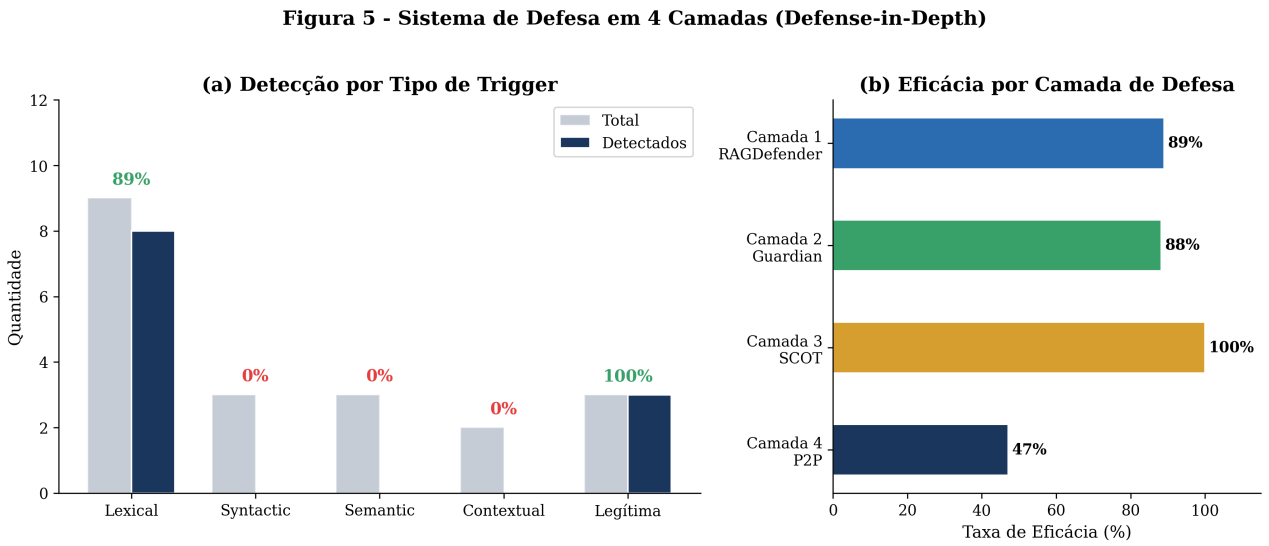

Figura 5: Sistema de defesa: (a) detecção P2P por tipo de trigger, (b) eficácia por camada de defesa.

[3] D. Sousa, "Arquitetura LLM para Tribunais – Sistema e Criação," Referencial Técnico, 2025.

[4] D. E. Ho, "Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools," *Stanford University*, 2024.

[5] European Parliament, "Article 15: Accuracy, Robustness and Cybersecurity," *EU Artificial Intelligence Act*, 2024.

[6] AI Act Service Desk, "Article 15," *European Union*, 2024.

[7] UC Berkeley, "System Architecture for Agentic LLMs," *eScholarship*, 2025.

[8] UC Berkeley, "Alpha Berkeley: A Scalable Framework for Agentic Systems," *arXiv:2508.15066v1*, 2025.

[9] UC Berkeley, "System Architecture for Agentic LLMs," *Tech. Report EECS-2025-5*, 2025.

[10] J. Niklaus et al., "Elevating Legal LLM Responses: Harnessing Trainable Logical Structures," *arXiv:2502.07912*, 2025.

[11] J. Niklaus et al., "Elevating Legal LLM Responses," *ResearchGate*, 2025.

[12] P. Colombo et al., "SaulLM-7B: A pioneering LLM for Law," *arXiv:2403.03883*, 2024.

[13] P. Colombo et al., "SaulLM-7B," *Hugging Face Papers*, 2024.

[14] P. Colombo et al., "SaulLM-7B," *arXiv:2403.03883*, 2024.

[15] Continuum Labs, "Better Call Saul – SaulLM-7B," 2024.

[16] LegNER, "A domain-adapted transformer for legal NER and text anonymization," *PMC, NIH*, 2023.

[17] Dataloop AI, "Legal Bert Base Uncased," 2024.

[18] Emergent Mind, "Agentic SFT Dataset Overview," 2025.

[19] "HyPA-RAG: A Hybrid Parameter Adaptive RAG System," *ACL Anthology*, 2024.

[20] "HyPA-RAG," *arXiv:2409.09046v2*, 2025.

[21] "HyPA-RAG," *ResearchGate*, 2024.

[22] D. Rosati, "Representation Noising: Defence Against Harmful Finetuning," *OpenReview*, 2024.

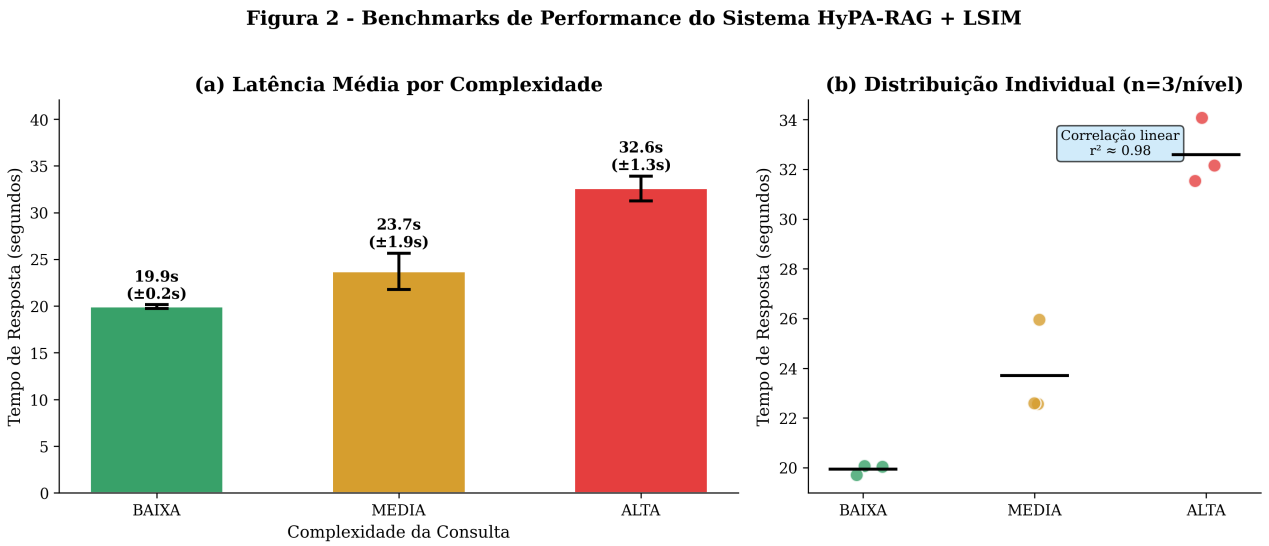

Figura 6: Benchmarks de performance: (a) latência média por complexidade com barras de erro, (b) distribuição individual (n=3 por nível).

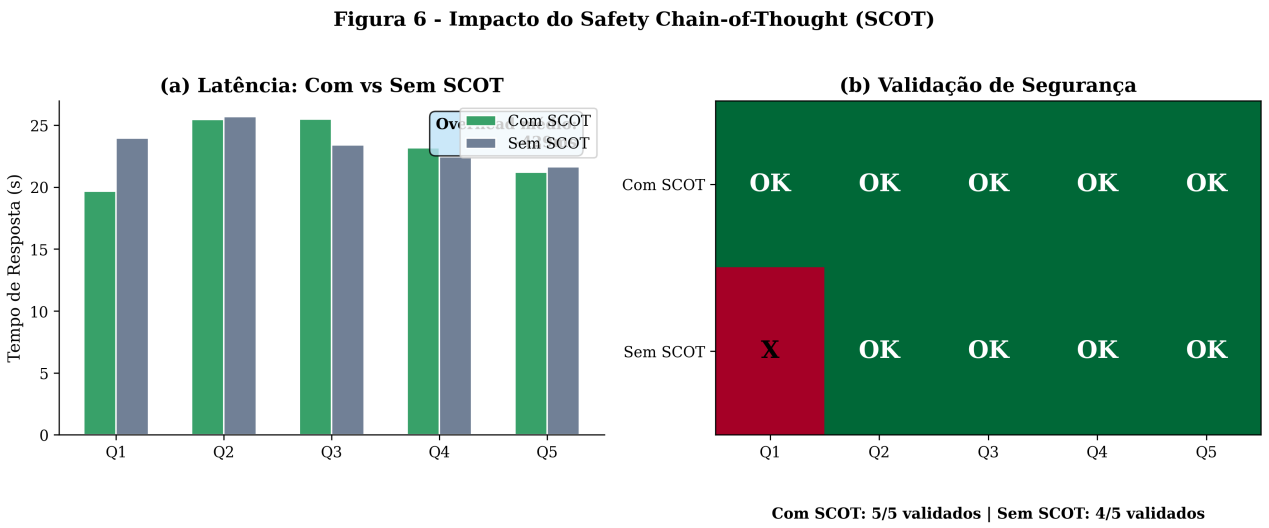

Figura 7: Impacto do SCOT: (a) latência com vs. sem SCOT, (b) heatmap de validação de segurança.

[23] D. Rosati, "Immunization against harmful fine-tuning attacks," *arXiv:2402.16382*, 2024.

[24] "ShadowCoT: Cognitive Hijacking for Stealthy Reasoning Backdoors," *arXiv:2504.05605*, 2025.

[25] "Backdoor Attacks and Countermeasures in NLP Models," *ResearchGate*, 2025.

[26] Emergent Mind, "CoT-Hijacking Attacks Explained," 2025.

[27] Oxford Martin AI Governance, "Chain-of-Thought Hijacking," 2025.

[28] "ShadowCoT," *ResearchGate*, 2025.

[29] "ShadowCoT," *arXiv:2504.05605v1*, 2025.

[30] agiresearch, "ASB: Agent Security Bench," *GitHub*, 2025.

[31] "Rescuing the Unpoisoned: Defense against Knowledge Corruption on RAG," *arXiv:2511.01268v1*, 2025.

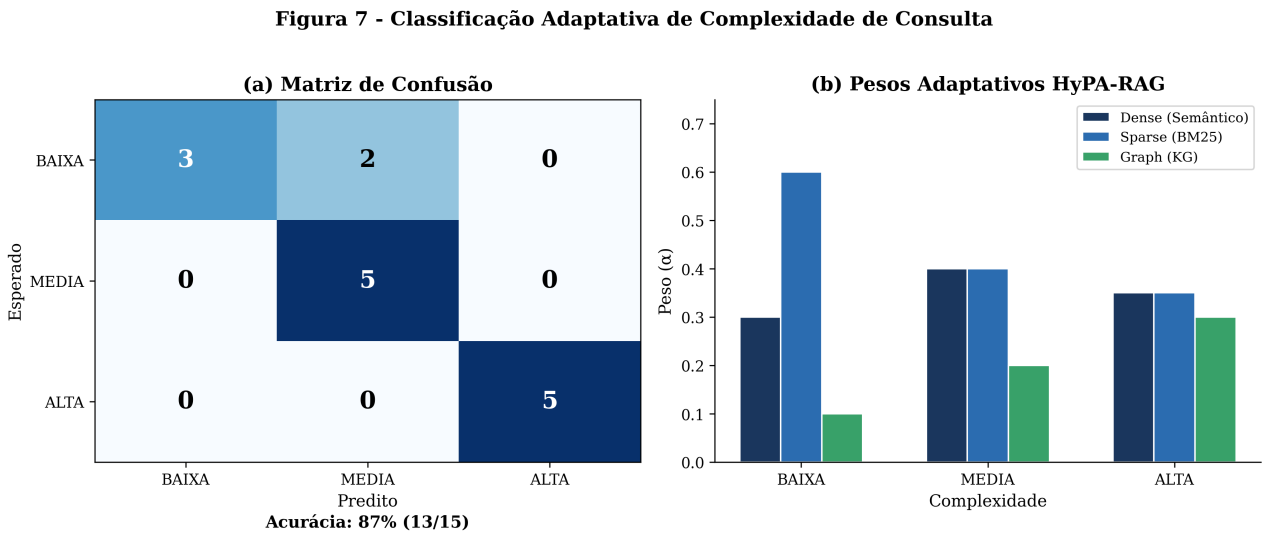

Figura 8: Classificação de complexidade: (a) matriz de confusão, (b) pesos adaptativos do HyPA-RAG por nível.

[32] "Rescuing the Unpoisoned," *arXiv:2511.01268*, 2025.

[33] "Benchmarking Robustness of Agentic Systems," *arXiv:2508.16481*, 2025.

[34] "Benchmarking Robustness of Agentic Systems to Adversarial Harms," *arXiv:2508.16481v1*, 2025.

[35] "Enhancing Model Defense with Proactive Safety Reasoning," *arXiv:2501.19180*, 2025.

[36] "Make Your Guard Learn to Think: Safety Chain-of-Thought," *arXiv:2501.19180v1*, 2025.

[37] "P2P: A Poison-to-Poison Remedy for Backdoor Defense in LLMs," *arXiv:2510.04503v1*, 2025.

[38] "P2P: Poison-to-Poison Remedy," *arXiv:2510.04503*, 2025.

[39] "Semantically-Aware LLM Agent to Enhance Privacy," *arXiv:2510.27016v1*, 2025.

[40] "Protecting Private Information While Preserving...," *OpenReview*, 2025.

[41] A. Vassiliades et al., "Argumentation-Based Explainability for Legal AI," *arXiv:2510.11079*, 2025.

[42] A. Vassiliades et al., "Argumentation-Based Explainability for Legal AI," *arXiv:2510.11079*, 2025.

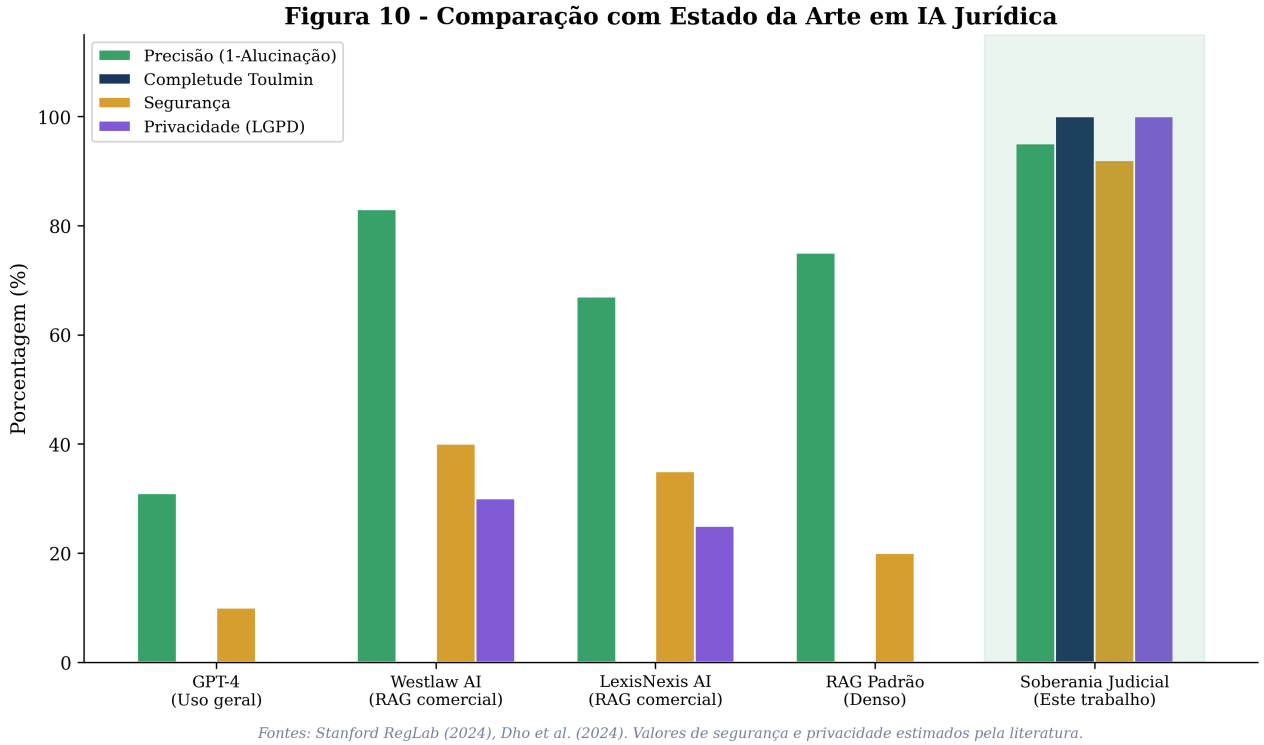

Figura 9: Comparação com estado da arte em IA jurídica. Fontes: Stanford RegLab [4], Magesh et al. [2].